

情報数学III

第1回：ガイダンス・データの分類と尺度

鈴木源吾

今回のトピック

1. ガイダンス・統計学とは？

- 講義ルールの説明
- 教科書・参考書について
- なぜ統計学を学ぶのか？
- 記述統計学と推測統計学

2. 使用するソフトウェア環境：PythonとGoogle Colab

- 演習の提出方法

3. データの分類・尺度（分布は次回）

- 測定尺度とデータ

教科書：第1部，第2部，第3部 第1章

1. ガイダンス・統計学とは？

講義に関する情報

鈴木の講義に関する情報

- 鈴木を担当科目の学生ポータルを参照すること
- 学生ポータルのURLは、WebClass参照

講義に関するルール（進め方・評価など）

- 講義ルールのスライドで説明する
- 科目に関する情報を説明する（CP・DPとの関連性など）

教科書

教科書：Pythonで学ぶあたらしい統計学の教科書 第2版, 馬場真哉, 翔泳社

- ○：Pythonによる具体例が豊富，わかりやすい
- ○：統計モデルの記述があたらしめ
- △：統計の考え方の記述がやや弱い

参考書

参考書：入門 統計学 第2版, 栗原伸一, オーム社

- ○：農学部の方が書いた，使う側にたった実践的な内容
- ○：幅広く手法が取り上げられている（ノンパラメトリック手法含む）
- △：やや農学部などの実験系の学生向け（少し古い）
- 2024年度までの教科書，辞書的に使える

参考書：統計モデルと推測, 松井秀俊他, 講談社

- ○：統計モデルの考え方など，数学的な内容がきっちり書かれている
- △：かなり難しい

なぜ統計学を学ぶのか？ -- 企業内実習を例に

皆さんが，企業内実習に行くことを考えよう

- 実習先の指導者から，課題をもらう
 - 例) 広告クリック数を増やしたい
- その課題の解決案を立案する
 - 例) 広告の位置を変更する
- その解決案が効果があるかを，実験してデータをとる：
 - 例) 変更なし・変更ありで，一定期間でクリック数を測定する

クリック数が増えた→よって，解決案は効果があった

・・・でいいのか？？？→科学的な判断と言えるのか？

なぜ統計学を学ぶのか？ -- 統計学の役割

- 本当に解決案がよかったからクリック数が増えたのか？
- 偶然，そうなたただけなのではないか？
- 解決案の正しさを言うためには，非常に多くのデータをとらないといけないのでは？→実際には無理．期間も限られている

統計学では，「95%の確率で，ある値がこの区間に含まれている」などと判定する
(注意：厳密にはこの言い方は正確ではない)

- 統計学は，**限られたデータ**で，真の結論を**推測する**ための知恵を教えてくれる
- 統計学は，データを間違って解釈してしまうことを防いでくれる
- 統計学は，科学的・客観的に実験し，他人を納得させる結論を引き出すため必須

なぜ統計学を学ぶのか？ -- 確率論と推測統計学

「95%の確率で・・・」→統計学の基本は**確率論**である


- 効果を，確率を用いて定量的に示すことができる

「限られたデータで・・・推測する」→推測統計学

- この講義の中心は，推測統計学（後で説明）
- ビッグデータ時代だったら，推測しなくていいのでは？
→これは間違い．統計学の知見は，データサイエンスの基礎として非常に重要

事例：オバマ陣営の選挙戦略 -- 問題

次の4つのメーリングリスト登録画面のうちどれが最も効果的だと思いますか？
(伊藤「データ分析の力 因果関係に迫る思考法」(光文社新書)より引用)



事例：オバマ陣営の選挙戦略 -- 結果



事例：オバマ陣営の選挙戦略 -- A/Bテストの威力

テストの結果：B

- 2008年，オバマ陣営は選挙活動の一環として，より多くの人にメーリングリスト登録をしてもらうための「画面のテスト」を行った．
- ウェブサイトを訪れた人に対して，ランダムに4つの画面のどれかを表示し，登録率を比較した（これが A/B テスト）．
- 最も効果的な画面は，登録率が他と比べて40%以上高く，結果として6,000万ドル以上の寄付が集まったと報告されている．

こんなところにも統計学！

- 🎓 希望大学の合格可能性
- 🧑 BMIによる体格の判定
- 🗳️ 選挙速報での「当確」判定
- ☔ 天気予報の降水確率
- 🧓 将来の年金支給額
- 📺 テレビの視聴率
- 🚗 帰省時の道路渋滞予測
- 💡 …他にもたくさん！

2つの統計学

- 統計学には，記述統計学と推測統計学がある
- 特に後者は，実験結果を評価するために重要

記述統計学 (descriptive statistics)

- 集めたデータの特性を明らかにする
- 平均・分散などを求めてデータを整理
- F・ゴールトン, K・ピアソンなどによって確立
- 参考：統計学者の様々なエピソードが、参考書の入門統計学に載っており、面白い

推測統計学 (inferential statistics)

- 集めた部分的データ（標本）から，その背景にある全体（母集団）の特性を推測する
- 点推定，信頼区間の推定，差の検定などがある
- R・フィッシャー，J・ネイマン，E・ピアソン（K・ピアソンの息子）らによって確立
- 実験結果の分析で使う統計学と言えば推測統計学
- 第4回以降で扱う

2. PythonとGoogle Colab

使用するソフトウェアと試験での使用

- 本講義では，統計の検定などの実施と，計算過程の確認には主にPythonを使う
 - 実用上と，基本を身につけるためには，Excelにある程度習熟することが必要（ちょっとした集計の実施など）．時間の許す範囲で取り上げる
 - Rも広く使われているが，最近はPythonでかなり間に合うようになってきた
 - GUIベースの統計ツールとしてjamovi・JASPなどもある（Rベース，無料）
 - 2027年度以降，jamoviの導入を予定している
- **小テスト・最終試験はペーパーテストで実施する**
 - 持ち込み可能な資料：教員が配布したポイント資料のみ
 - 詳細は講義ルールを参照

Google Colabと演習の提出方法

- 環境はGoogle Colabを利用する
- ノートブックの配布と利用の仕方
- **演習の提出の練習**：M3_00ノートブックの手順に従って実施する
 - ドライブにコピー→ファイル名を学籍番号に変更→共有設定→URLをWebClassに提出
- 教科書2-2 Jupyter Notebook→実施しておくこと
- 教科書2-3 Pythonによるプログラミングの基本→実施しておくこと
- 教科書2-4 numpy・pandas→データフレームの説明

3. データの分類・尺度

記述統計学を始めるために

記述統計学は、**平均や分散などのデータの特性を求める**手法だった

では、すべてのデータに対して、平均や分散を求めるような、数値演算を行ってよいものだろうか？

→ データを**尺度**（単位）によって分類して考える必要がある

データを扱う基本として重要

- しかし、意外だが、この基本的な考え方すら一般に浸透していない
（統計教育が軽視されていたため）

測定尺度によるデータの分類

測定尺度とは？

→ 数値データをどのような単位で測定されているか、その単位のこと
データは、様々な尺度によって測定されている

- きゅうりの長さのデータが21cmである→測定尺度は長さ
- 気温が摂氏20度である→測定尺度は温度
- 男性を1，女性を2にする
- 満足度を5段階で表す（5:大変満足，4:満足，・・・）

測定尺度の種類

測定尺度には、以下の4つがある（重要）

1. 比率尺度
2. 間隔尺度
3. 順序尺度
4. 名義尺度

1→4の順序で、数値的な扱いがしづらい尺度となる

比率尺度 -- 定義と具体例

絶対的なゼロ点を持っている測定尺度を，**比率尺度**と呼ぶ

・・・というとし分かりにくい．

比率尺度とは，「比率をとることに意味のある」尺度と考えるとよい

例) 長さは比率尺度か？

- 20cmのきゅうりと40cmのきゅうりがある．このデータの比率をとると後者は前者の2倍となる．この比率には意味があるから比率尺度（2本分の量がある）

例) 温度は比率尺度か？

- 気温10度と気温20度の日がある．このデータの比率をとると後者は前者の2倍となる．しかし，この2倍に意味は見いだせない（2倍暑いというわけじゃない）．よって比率尺度ではない

比率尺度 -- 絶対的なゼロ点

前スライドの例の長さや温度の違いは何か？

長さ：絶対的な0がある．長さが0というのは本当に長さがないという意味

温度：絶対的な0がない．温度が0というのは，どこか適当な温度を0と決めただけ

→0が何もないことを意味する→比率に意味がある→比率尺度

例) 持っているお金の金額は比率尺度か？

- 10000円持っている人は，5000円持っている人より2倍金持ちだと言ってよい．比率に意味があるから比率尺度である

比率尺度 -- 許される演算

比率尺度で許される演算は何か？

- 足し算
- 引き算
- かけ算
- 割り算

と四則演算すべてが許される

間隔尺度 -- 定義と具体例

では、温度のような（量的だが）比率をとることに意味のないような尺度を何と呼ぶか？

→ **間隔尺度**

定義：絶対的なゼロ点を持っていない量的データ

- 間隔の値には意味があるが、比率の値には意味を持たない
- 「今日は昨日より5度暑い」は意味があるが、「今日は昨日の2倍暑い」は意味がない
- 「5度と10度の差の5度」と「10度と15度の差の5度」は同じ意味

間隔尺度 -- 許される演算

間隔尺度で許される演算は何か？

- 足し算
- 引き算

しかし、かけ算と割り算は許されない

比率尺度と間隔尺度で、平均や分散は計算できるの？

- 算術平均：データの値をすべて加えて個数で割る
- 分散：平均とデータの値の差の2乗を加えて個数で割る

→ ということは、上の2つでは、データ間のかけ算・割り算は行っていない

→ 比率尺度でも間隔尺度でも、算術平均と分散は計算してよい

注意：ただし、後で出てくる幾何平均は、間隔尺度では許されない

順序尺度 -- 定義と具体例

順序・順位などしか表していない尺度を**順序尺度**と呼ぶ

- 比率にも意味がないし，間隔にも意味がない
- でも，順序には意味がある，という尺度

最も典型的な順序尺度は，アンケート調査における満足度

例) 5: 大変満足，4: 満足，3: どちらともいえない，2: 不満，1: 大変不満

- 1→2→3→4→5の順序で満足度はアップ
- 5と4の差と2と1の差は，1で等しいが同じ意味ではない（間隔尺度じゃない）

順序尺度 -- 許される演算

- $>, =$ といった大小比較

四則演算（足し算，引き算，かけ算，割り算）は許されない

→ 重要：原則としては，**順序尺度で平均を求めるべきではない**

- 値の間隔に意味がないことから，誤った分析を行うリスクがある
- 中央値や最頻値を用いるべき（次回学ぶ）
- これは，世の中で結構守られていない

順序尺度と平均 -- 授業評価アンケートの例

皆さんが回答した授業評価アンケートを思い出してみよう

- 例)「毎回の授業の目標やポイントが明確でしたか」→平均4.74ポイント

5: と思う, 4: どちらかと言えばと思う, 3: どちらとも言えない, 2: あまりそう思わない, 1: そう思わない

- これは厳密には順序尺度ではないのか？
- このように間隔を配慮した5個の回答を用いる方法を5件法と呼ぶ
- 5件法以上は, 間隔尺度とみなしてよいというコンセンサスがある

順序尺度と平均 -- 間隔が不均等な場合

もう一つ同じアンケートの例

- 授業1回につき，平均してどの程度時間外学習をしていたか？→平均2.49ポイント

5: 4時間以上，4: 約3時間，3: 約2時間，2: 約1時間，1: 30分未満

→ これは間隔が一定じゃないから，順序尺度と考えるべき

→ これは，ポイントが時間の長さで混同しそうなので，注意が必要
(ちなみに，時間の期待値を概算すると約1.6時間)

名義尺度 -- 定義と具体例

順序ももたない，内容を区別するだけに用いられる尺度を**名義尺度**と呼ぶ

- 比率・間隔・順序，すべての意味はない
- 値の区別だけに意味がある

例)

- 男性→1，女性→2のような性別のデータ
- 血液型を区別するデータ

名義尺度 -- 許される演算

- 度数のカウント（例：男性何人，女性何人），のみ

四則演算（足し算，引き算，かけ算，割り算）も，大小比較も許されない

注：順序尺度や名義尺度のデータを分析されるための統計的手法はある
（ノンパラメトリック手法→参考書の入門統計学に記載あり）

測定尺度の一覧

これまでの結果をまとめると以下のようなになる

- 量的な計算ができないアンケートの結果のようなデータを質的データと呼ぶ
- 名義尺度で測定されたデータをカテゴリデータと呼ぶことがある
 - 電話番号をカテゴリデータと呼んでよいかは微妙だがこの分類は一般的

	データの名称	測定尺度	直接できる演算	主な代表値	主な事例
量的データ	比率データ	比率尺度	$+-\times\div$	各種平均	質量, 長さ, 年齢, 時間, 金額
	間隔データ	間隔尺度	$+-$	算術平均	温度（摂氏）, 知能指数
質的データ	順位データ	順序尺度	$>=$	中央値・最頻値	満足度, 選好度, 硬度
	カテゴリデータ	名義尺度	度数カウント	最頻値	電話番号, 性別, 血液型