

情報数学III

第2回：記述統計：様々な統計量

鈴木源吾

前回の復習

1. ガイダンス

- 講義に関するルール：演習・評価など
- 教科書・参考書について
- なぜ統計学を学ぶのか？

2. 様々なデータと統計学

- 記述統計学と推測統計学
- 測定尺度とデータ

今回のトピック

1. 度数分布表とヒストグラム

- 度数分布表の作成
- ヒストグラムの作成

2. 様々な代表値

- 平均
- 分散と標準偏差
- 変動係数
- ピアソンの積率相関係数

教科書：第3部 第2-5章

1. 度数分布表とヒストグラム

データとその整理

これから統計学やデータサイエンスを学んでいくが、どんなデータを扱うのか．少しイメージを持つために例を考えよう

例：ゲームのプレイ時間を分析したい（例えば，若者のプレイしすぎを懸念する教育関係者や，逆にゲームにもっと課金させたいゲーム会社のマーケティング担当になったとする）．

- 年代別でプレイ時間はどう違うだろう？
- 性別でプレイ時間はどう違うだろう？
- 新潟県と東京都ではプレイ時間に違いはあるのか？
- 血液型でプレイ時間は違うのか？？

データの例：ゲームのプレイ時間

前ページにあげたような疑問に答えようとする、以下のようなデータを集めることになるだろう

- 一つの行が一人のデータを表している
- その人の1日あたりの平均ゲームプレイ時間と、その人の様々な属性が含まれる

データの例：ゲームのプレイ時間

- この例の場合、プレイ時間という変数は、年齢や性別などの原因によって決まる変数と考えられ、以下のように呼ばれる
 - 原因となる変数→説明変数
 - 結果となる変数→目的変数
- データサイエンスではこのような多変量のデータを扱う

データの可視化の基本：度数分布表

まずは、プレイ時間のみの1変数のデータに着目しよう（以下の10個）

3, 2.5, 4, 1.5, 0.5, 5.5, 1, 3, 2.5, 1.5

データを見た時にまずは、その**全体的な傾向を視覚化**して把握することが大切

その基本は、値の階級毎のデータの数＝度数 を数えることである

- この例では、階級を、0～1時間、1時間～2時間、・・・とすればよさそう
- 階級と度数の対応をとったものが**度数分布表**である

度数分布表

プレイ時間の度数分布表を書いてみよう。基本は下表になる。

3, 2.5, 4, 1.5, 0.5, 5.5, 1, 3, 2.5, 1.5

度数分布表

度数分布表には，以下の値を入れるとさらにわかりやすくなる．

（全体の数が異なる2つのデータを比較するときはわかりやすい）

- 相対度数：その階級に入るデータの全体に対する割合（パーセント）
- 累積相対度数：相対度数を累積した値（パーセント）

階級の数を決めるか？

プレイ時間の例では、1時間毎に分けて階級を決めればよいことが直感的にわかったが、そうでない場合もある

例) キュウリの収量

階級の数を決めるか？

決め方の目安：「データ数の平方根+1」

- 前ページの例を，栽培法を区別しない30個の収量のデータと考えよう
- データの数は30だから，データ数の平方根+1は，約6.5→階級数を7とする
- 区間の幅は，等分すれば良い
 - 最小値：1757g，最大値：3633gの差を求める→1876g
 - 差を7で割ると，約268g→きりのよいところで300gとする

他にスタージェスの公式 $\log_2 n + 1$ という目安も有名．こちらの方がnが大きいときに小さめになる．暗算なら上記方式が楽だが，Python・Excelでlogはすぐ計算できる

度数分布表の例

前ページのように階級を決めれば，以下のような度数分布表ができる

- 階級値とは，階級を代表する値である（例：階級の真ん中の値）

ヒストグラム

- 階級と度数を（隙間のない）柱状のグラフとして表したものがヒストグラム
- 度数分布表をそのままグラフ化すればよい
- データの可視化としては、基本だが大変便利

↓ゲームのプレイ時間のヒストグラム→演習ファイルにPythonでの作成方法あり

2. 様々な代表値

代表値とは？

「データの特性を表す，何らかの統計的な計算をしてえられた数値」

例) 平均，分散，相関係数

- 記述統計量，基本統計量，要約統計量などとも呼ばれる

様々な平均：算術平均

$x_1, x_2, \dots, x_n$ の n 個のデータがあるとする

算術平均

いわゆる「普通の」データの平均．足して個数で割る

$$\bar{x} = \frac{x_1 + \dots + x_n}{n}$$

平均を表す記号について

- 推測統計学では，すべてのデータを表す「母集団」から，その一部である「標本」を抜き出し，標本の性質から母集団の性質を推定する
- $\bar{x}$ は，標本の平均を表すときに使う．一方，母集団の平均を表すときは， μ を使うことが多い

様々な平均：加重平均

測定されたデータの値に対して，重み（ウェイト）をかけて考える場合がある

例）大学の入試で，英語と数学のテストがあり，両方とも100点満点だが，（数学に強い学生を取りたい大学が）数学に2倍の重みをかけたい

→ このような場合は，**加重平均**により合否を判定すればよい

$$\bar{x}_w = \frac{w_1 x_1 + \cdots + w_n x_n}{w_1 + \cdots + w_n}$$

上記の例で，

数学：65点，英語：80点の学生の加重平均は， $\frac{2 \times 65 + 1 \times 80}{2 + 1} = 70$ 点

数学：80点，英語：65点の学生の加重平均は， $\frac{2 \times 80 + 1 \times 65}{2 + 1} = 75$ 点

- 数学ができる方が，英語ができるより有利

様々な平均：幾何平均

幾何平均は、以下で定義される．データをすべて掛けてn乗根を取る（相乗平均とも呼ばれる）

$$m_g = \sqrt[n]{x_1 x_2 \cdots x_n}$$

幾何平均は、算術平均に比べて**外れ値**の影響を受けにくいという特性がある

- 1つ極端な値があっても、大きく平均が変化しない
- それは、幾何平均が、元のデータの対数をとったものの算術平均に近い挙動をするからである（正確にはさらに指数変換したもの．次ページに解説）
 - 対数は、値の増加スピードが抑えられるから（logのグラフを思い出そう）

幾何平均と対数

幾何平均は，元のデータの対数をとったものの算術平均を，さらに指数変換したものになっている．例えば，2変数の幾何平均を考えてみよう

$$m_g = (x_1 x_2)^{\frac{1}{2}}$$

で，両辺の対数をとれば，

$$\begin{aligned} \log m_g &= \log (x_1 x_2)^{\frac{1}{2}} \\ \log m_g &= \frac{1}{2} \log x_1 x_2 = \frac{\log x_1 + \log x_2}{2} \end{aligned}$$

変化率には幾何平均

例：

2年前から1年前 → 物価が2倍

1年前から今年 → 物価が8倍

このとき、この2年間の対前年比の平均は何倍か？

算術平均 $\rightarrow \frac{2+8}{2} = 5$ ，幾何平均 $\rightarrow \sqrt{2 \times 8} = 4$

100円だったものは $\rightarrow 200\text{円} \rightarrow 1600\text{円}$ になっている

よって、1年に平均4倍になったと考えると自然 $\rightarrow$ 幾何平均の方が合っている

移動平均

- 移動平均を一番身近に見るのは，コロナの感染者だろう．例えば，下のグラフは，新潟県の陽性者数だが，棒グラフが実際の陽性者で，折れ線グラフが移動平均である（その日の前後1週間の平均）．移動平均は，**グラフを滑らかにする**効果があり，曜日毎の陽性者の変化の影響を減らす

分散と標準偏差

情報数学Ⅱでやっていると思うが・・・

変量 x （身長や体重の記録のような特性を表す数量）の n 個のデータ $x_1, x_2, \dots, x_n$ があるとする．このとき，

$$\text{分散： } s^2 = \frac{1}{n} \{ (x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2 \}$$

$$\text{標準偏差： } s = \sqrt{\frac{1}{n} \{ (x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2 \}}$$

変動係数

変動係数とは，標準偏差を平均で割った値であり，以下で定義される

$$C.V. = \frac{s}{\bar{x}}$$

- ばらつきを表すという点では，標準偏差と同じ
- 平均で割ることによって，単位がなくなる（無名数と呼ぶ．標準偏差の単位は元のデータの単位となることを思い出そう）
- 平均が異なるグループのばらつきを比較したり，異なる単位のグループのばらつきを比較するのに使える
 - 例：男女の体重のばらつきを比較する（標準偏差だと男が大きめになる）
- 平均が0のときは使えない

質的データの代表値

質的データでは、平均を使うことができなかった．その代わりに以下を使う

最頻値

- ヒストグラムで最大の度数を持つ階級の階級値

中央値

- データを大小で並べたときに，その中央（真ん中）にある値

相関係数

情報数学Ⅱでも出てきたと思うが・・・

データに関する相関係数は、以下の式で与えられる

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

相関係数とデータ

- 相関係数の値は-1～1まで. 1に近いほど正の相関が強く (xが大きくなるとyも大きくなる), -1に近いほど負の相関が強い (xが大きくなるとyは小さくなる). 0に近いほど相関が弱くなる

統計量に関する演習

- 統計量に関する演習は，次回に回す
- サンプルコードについては，次回に補足説明する