

情報数学III

第3回：記述統計：層別分析・グラフの活用

鈴木源吾

前回の復習

1. 度数分布表とヒストグラム

- 度数分布表の作成
- ヒストグラムの作成

2. 様々な代表値

- 平均
- 分散と標準偏差
- 変動係数
- ピアソンの積率相関係数

今回のトピック

1. 層別分析

- 整然データとクロス集計表
- 層別分析

2. グラフの活用

- 散布図
- 四分位点と箱ひげ図
- ペアプロット

教科書：第3部 第6-7章

1. 層別分析

前回の補足：説明変数と目的変数

- この例の場合、プレイ時間という変数は、年齢や性別などの原因によって決まる変数と考えられ、以下のように呼ばれる
 - 原因となる変数→説明変数
 - 結果となる変数→目的変数
- データサイエンスではこのような多変量のデータを扱う

目的変数		説明変数		
プレイ時間/日	年齢	性別	都道府県	血液型
3	15	男	新潟県	A
2.5	19	女	東京都	B
4	35	男	神奈川県	A
1.5	51	男	新潟県	O
0.5	28	女	長野県	AB

変数に関する用語

- いろいろな呼び方がある
- 今後も、情報数学Ⅲでは、説明変数＋目的変数を使用する

	原因側の変数	結果側の変数
教科書	説明変数	応答変数
参考書	説明変数	被説明変数
DS演習	説明変数	目的変数
その他	独立変数	従属変数

入門 統計学

用語はデータサイエンス演習とそろえておく

整然 (tidy) データ

このような「整えられた」データを，整然 (tidy) データと呼ぶ

- 個々の値が1つのセルをなす (参考：集計値じゃない)
- 個々の変数が1つの列をなす
- 個々の観測が1つの行をなす
- 個々の観測ユニットの類型が1つの表をなす

目的変数		説明変数		
プレイ時間/日	年齢	性別	都道府県	血液型
3	15	男	新潟県	A
2.5	19	女	東京都	B
4	35	男	神奈川県	A
1.5	51	男	新潟県	O
0.5	28	女	長野県	AB

クロス集計表とは？

まず、クロス集計表とは何か、とその用語を整理しよう

一つの変数の分布を調べたいとき → 基本は「度数分布表」だった

例) 学歴と好きなスポーツの度数分布表

→ 高卒で野球の好きな人はどれだけだろう？・・・等も知りたい

	度数	相対度数
高卒	150	50.0%
短大卒	50	16.7%
大卒	100	33.3%
計	300	100.0%

	野球	サッカー	その他	計
度数	120	150	30	300
相対度数	40.0%	50.0%	10.0%	100.0%

クロス集計表

2つの（離散）変数間の関連を表にしたものが**クロス集計表**である

- 2つの変数のカテゴリーが重なった（クロスした）ケースの数を算出して表示

	野球	サッカー	その他	計
高卒	80	50	20	150
短大卒	15	30	5	50
大卒	25	70	5	100
計	120	150	30	300

クロス集計表の用語

セル		野球	サッカー	その他	計	表頭 ひょうとう
セル 度数	高卒	80	50	20	150	行周辺度数 行方向の合計
	短大卒	15	30	5	50	
	大卒	25	70	5	100	総度数
表側 ひょうそく	計	120	150	30	300	列周辺度数 列方向の合計

相対度数の表示

クロス集計表の場合、相対度数は、行パーセントと列パーセントの2種類の表し方がある（両方表示すると混乱するので、どちらかを見たい関係性によって選ぶ）

行パーセント

行周辺度数で割る

	野球	サッカー	その他	計
高卒	53.3%	33.3%	13.3%	100.0%
短大卒	30.0%	60.0%	10.0%	100.0%
大卒	25.0%	70.0%	5.0%	100.0%
計	40.0%	50.0%	10.0%	100.0%

学歴毎に好きなスポーツが異なる関係性を見る

列パーセント

列周辺度数で割る

	野球	サッカー	その他	計
高卒	66.7%	33.3%	66.7%	50.0%
短大卒	12.5%	20.0%	16.7%	16.7%
大卒	20.8%	46.7%	16.7%	33.3%
計	100.0%	100.0%	100.0%	100.0%

好きなスポーツ毎に学歴が異なる関係性を見る

層別分析

- 似たものをいくつかのグループに分けることを「**層別する**」と呼ぶ
- 層別に分析を行うことを「**層別分析**」と呼ぶ

例)

- 学歴で層に分ける→好きなスポーツを分析する

Pythonによる層別分析

ノートブックを使って解説


- groupby関数（SQLのgroup byと似ている）
- ペンギンのデータを利用
 - 種（species），島（island），性別（sex）
 - クチバシ（bill）の長さ（length）と厚み（depth）
 - 体重（body_mass）

2. グラフの活用

散布図

2次元データの観察の基本！

- 2つの数量データ同士の関係性を見る
- ノートブックで解説




四分位点（しぶんいてん．四分位数とも呼ぶ）

- 英語のquartileの訳．4分の1ずつ分けるための基準点
- データを昇順で並び替えたとき，
 - 25%に位置する値→第1四分位点
 - 75%に位置する値→第3四分位点
- 中央値は，50%に位置する値

箱ひげ図

- 箱の下端と上端は四分位点
- ひげはデータの範囲（最小値と最大値）



ペアプロット

- 複数の散布図を並べたグラフを描ける
- 数量データのすべての組み合わせに対して散布図を書く
- 対角線上は，カーネル密度推定の結果

