

情報数学III

第3回：記述統計：層別分析・グラフの活用

鈴木源吾

前回の復習

1. 度数分布表とヒストグラム

- 度数分布表の作成
- ヒストグラムの作成

2. 様々な代表値

- 平均
- 分散と標準偏差
- 変動係数
- ピアソンの積率相関係数

今回のトピック

1. 層別分析

- 整然データとクロス集計表
- 層別分析

2. グラフの活用

- 散布図
- 四分位点と箱ひげ図
- ペアプロット

教科書：第3部 第6-7章

1. 層別分析

前回の補足：説明変数と目的変数

- この例の場合、プレイ時間という変数は、年齢や性別などの原因によって決まる変数と考えられ、以下のように呼ばれる
 - 原因となる変数→説明変数
 - 結果となる変数→目的変数
- データサイエンスではこのような多変量のデータを扱う

変数に関する用語

- いろいろな呼び方がある
- 今後も，情報数学Ⅲでは，説明変数＋目的変数を使用する

整然 (tidy) データ

このような「整えられた」データを，整然 (tidy) データと呼ぶ

- 個々の値が1つのセルをなす (参考：集計値じゃない)
- 個々の変数が1つの列をなす
- 個々の観測が1つの行をなす
- 個々の観測ユニットの類型が1つの表をなす

クロス集計表とは？

まず，クロス集計表とは何か，とその用語を整理しよう

一つの変数の分布を調べたいとき → 基本は「度数分布表」だった

例) 学歴と好きなスポーツの度数分布表

→ 高卒で野球の好きな人はどれだけだろう？・・・等も知りたい

クロス集計表

2つの（離散）変数間の関連を表にしたものが**クロス集計表**である

- 2つの変数のカテゴリーが重なった（クロスした）ケースの数を算出して表示

クロス集計表の用語

相対度数の表示

クロス集計表の場合、相対度数は、行パーセントと列パーセントの2種類の表し方がある（両方表示すると混乱するので、どちらかを見たい関係性によって選ぶ）

層別分析

- 似たものをいくつかのグループに分けることを「**層別する**」と呼ぶ
- 層別に分析を行うことを「**層別分析**」と呼ぶ

例)

- 学歴で層に分ける→好きなスポーツを分析する

Pythonによる層別分析

ノートブックを使って解説

- groupby関数（SQLのgroup byと似ている）
- ペンギンのデータを利用
 - 種（species），島（island），性別（sex）
 - クチバシ（bill）の長さ（length）と厚み（depth）
 - 体重（body_mass）

2. グラフの活用

散布図

2次元データの観察の基本！

- 2つの数量データ同士の関係性を見る
- ノートブックで解説

四分位点（しぶんいてん．四分位数とも呼ぶ）

- 英語のquartileの訳．4分の1ずつ分けるための基準点
- データを昇順で並び替えたとき，
 - 25%に位置する値→第1四分位点
 - 75%に位置する値→第3四分位点
- 中央値は，50%に位置する値

箱ひげ図

- 箱の下端と上端は四分位点
- ひげはデータの範囲（最小値と最大値）

ペアプロット

- 複数の散布図を並べたグラフを描ける
- 数量データのすべての組み合わせに対して散布図を書く
- 対角線上は，カーネル密度推定の結果