

情報数学III

第4回：統計で必要となる確率と確率分布

鈴木源吾

前回の復習

1. 層別分析

- 整然データとクロス集計表
- 層別分析

2. グラフの活用

- 散布図
- 四分位点と箱ひげ図
- ペアプロット

今回のトピック

1. さまざまな確率分布

- 一様分布
- 二項分布
- 正規分布
- ポアソン分布

2. 正規分布の復習

- 正規分布の性質

3. 確率分布の標準化，歪度，尖度

- 標準化
- 歪度・尖度

1. さまざまな確率分布


確率分布(probability distribution)

- 確率変数の値とそれが出る確率との対応関係を示したもの
 - 確率変数：サイコロを振る実験において出る目のように、確率が決まっている変数のこと
- 各種の統計手法は、母集団（統計の調査対象の全体）が、何らかの確率分布に従っていると仮定する
- 色々な確率分布を確率の学習で学んだが、本科目で扱う統計学ではさらに、t分布、 χ^2 分布、F分布といった重要な分布を学んでいく

X	1	2	3	4	5	6	計
P	1/6	1/6	1/6	1/6	1/6	1/6	1


サイコロの事例（一様分布）

最も基本的な確率分布は一様分布である．下図のように，確率変数の値に対して全く同じ確率となるような分布である．




いろいろな確率分布

様々な確率分布があるが，下図のように分類される．離散型か連続型かという分類は重要である．




確率分布の形を見てみよう

- Web上には確率分布の計算・描画サービスがあるので、利用してみよう
- サービス例：「ke!san」 <http://keisan.casio.jp/>
 - 電卓のカシオが運営する様々な計算ができたり、グラフがかけられるサイト
 - 統計に使うグラフは、「専門的な計算」のタグを選択するとでてくる
 - 適当な確率分布を選ぶとグラフが表示され、計算を押すと確率の値がわかる




いろいろな確率分布曲線


連続型の場合もある




一様分布




二項分布




ポアソン分布




(標準) 正規分布



t分布



χ^2 分布




F分布

ke!+san (<http://keisan.casio.jp/>) 上で描写

二項分布(binomial distribution)

二項分布も極めて重要な確率分布


- ベルヌーイ試行 (Bernoulli trial)を n 回繰り返したときの成功数で表した離散分布




コイン投げの二項分布→正規分布

コイン投げの実験を図式的に表し，正規分布に近似するイメージを見てみよう
表が出れば成功：1点，裏が出れば失敗：0点 → 出たパターンをグラフ化

a) コインが1枚の場合($n=1$)




b) コインが2枚の場合($n=2$)




二項分布から正規分布へ

コインの数を増やしていくと...

c) コインが3枚の場合($n=3$)



d) コインが4枚の場合($n=4$)



コインの数を増やすと徐々に「つりがね型」に...

正規分布(normal distribution)

- 二項分布は試行回数（コインの枚数）が多いとき，特定の得点（表の出る数）の起きる確率を計算するのが大変

→ド・モアブルが確率密度関数で二項分布を近似させたのが正規分布

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$


μ : 平均
 σ : 標準偏差

母数 (= パラメータ)
→ 分布の形を決める統計量

e : ネイピア数 2.718...

確率密度関数とは

- 連続型の確率分布を表す数式のこと
- グラフとx軸に挟まれた部分の面積によって確率をあらわす
- 連続型の場合，確率変数のある特定の値に対する確率は0
- 離散型の場合には確率質量関数と呼び，確率変数と確率の値のグラフとなる




ポアソン分布(poisson distribution)

- 所定時間内にまれに起こる事象が，ある回数（イベント数）発生する確率の分布
 - （1年間に）地震の起こる回数，馬に蹴られて死ぬ兵士数，食中毒の件数
- 母数（パラメータ）が1つ（ λ ）しかないのが特徴
 - 平均も分散も $\lambda \rightarrow$ 平均が大きいとばらつきも大きい


平均で λ 回発生する事象が x 回

発生すると考えられる確率の式： $f(x) = \frac{e^{-\lambda} \lambda^x}{x!}$


$e^{-\lambda} \lambda^x$ ← λ ：平均
 $x!$ ← x の階乗



$\lambda=1$



$\lambda=5$



$\lambda=10$

ポアソン分布のグラフを書いてみよう

前ページの3つのグラフをPythonで（1つのグラフに）書いてみよう

→ 演習用ノートブックを参照

- `scipy.stats.poisson` ライブラリを使用する
- pmf関数（確率質量関数：probability mass function）を使用する

例題：ポアソン分布の適用例

★現実の問題を確率で解く重要な例題★ → 演習用ノートブックを参照
(解散は簡単だが、適用するのはそれなりに難しい)

日本では2006年4月-2011年3月の5年間にマグニチュード7以上の大きな地震は7回起きている．以下の問いに答えよ

1. 上記の5年間で地震の起こった実績から，3日間のうちにマグニチュード7以上の地震は，日本で平均何回起こるかを答えよ．1年は365日で計算せよ（小数点第5位以下を四捨五入せよ）
2. 3日間のうちにマグニチュード7以上の地震が起こる回数の確率は，まれに起こる事象なのでポアソン分布に従うと予測できる．では，このポアソン分布の平均が1.で求めた値であると仮定したときに，3日間のうちに1回以上マグニチュード7以上の地震が起こる確率はいくつか

topic 1 演習

厚生労働省によれば，日本では年間に20204人の食中毒が発生している（2006-2010年の平均値）．以下の問いに答えよ

(1) 千葉県松戸市（人口484600人）において，1日の食中毒の人数の平均はいくらかを，上記の日本の実績から求めよ．日本の人口は127370000人とする


ヒント：例題より少しだけ複雑である，松戸市と日本全体の人口比の考慮要

(2) 1日の間に食中毒にかかる人の人数はポアソン分布に従うと仮定し，問1で求めた平均の値を利用して，千葉県松戸市において，1日に食中毒にかかる人が0人である確率を求めよ

2. 正規分布の復習


正規分布の事例

- 自然界（体長，体重，体力…）や人間社会の事象（犯罪，結婚，自殺…）の多くが従う




2.3 正規分布の性質

- 曲線下の面積で、確率を求めることができる




正規分布は便利

- ある値 x_i がデータ全体のなかで上位（下位）何%に入っているかが簡単に分かる



この2つは覚えておく目安になる



- 正規分布する変数が平均値から ± 1 標準偏差内にある確率は約68%
- 同様に，平均値から ± 2 標準偏差内にある確率は約95%



正規分布を利用した例題

正規分布を利用する（正規分布であることを仮定する）と，以下の2種類のパターンの問題を解くことができる．


1. テストで80点以上取った人は，全体の何%いるか？
 - 下左図のパターン．x軸の値から確率を求める
2. テストで上位10%に入るためには，何点取れば良いか？
 - 下右図のパターン．確率の値からx軸の値を求める



正規分布を利用した例題：パターン1

x軸の値から確率を求める→ `norm.cdf()` 関数を使う（使い方：`norm.cdf(x, loc, scale)`）


- cdf：Cumulative Distribution Function（累積分布関数）
 - 「x 以下となる確率（＝下側確率）」を求める関数
 - `loc`：平均（ μ ）、`scale`：標準偏差（ σ ）
 - 例えば「上位10%に入る確率」は、「下位90%以下」に相当するため、上側確率を求めるには、`1 - norm.cdf(x, loc, scale)` とする必要がある



正規分布を利用した例題：パターン2

確率から x軸の値を求める→ `norm.ppf()` を使う (使い方: `norm.ppf(p, loc, scale)`)

- **ppf : Percent Point Function** (パーセント点関数. xをパーセント点と呼ぶ)
 - 「下側確率が **p** となる **x** の値」を返す関数 (`cdf` の逆関数)
 - **p** は「何%以下になるか」を表す確率 (例: 上位10%なら `p=0.90`)
 - `loc` : 平均 (μ)、`scale` : 標準偏差 (σ)
- 例「上位10%に入るには何点必要か？」は、`norm.ppf(0.90, loc, scale)` を使う



例題

統計学の試験の点数が、平均が60点・標準偏差が10の正規分布に従う場合、以下の問に答えよ

- (1) あなたの得点が80点だったとするとき、あなたはクラス全体の上位何%ぐらいの位置にいると考えられるか
- (2) クラスの上位10%に入るためには、あなたは最低何点とる必要があるか。
 - 解答は、演習用ノートブックに記載

3. 確率分布の標準化，歪度，尖度

標準化 (standardize)

- データ x_i を，平均 μ が0で標準偏差 σ が1の標準化変量 z_i に変換すること
- 標準化変量への変換式

$$z_i = \frac{x_i - \mu}{\sigma}$$


- 標準正規(z)分布

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$$

- 標準化すれば正規分布の式も簡単になる！

標準正規分布 = 「z分布」

- 標準化された正規分布をz分布と呼ぶ
- 平均が0で標準偏差が1であるような正規分布




標準正規分布表の使い方

- 現代はコンピュータで簡単に求められるようになってはいるが、参考書などに乗っている分布表の使い方は覚えておくとう理解の助けになる。



偏差値（z分布の応用）

- テストの得点などを，平均を50点，標準偏差を10点とみなして換算した値
- 偏差値 $T_i = \frac{10(x_i - \mu)}{\sigma} + 50$




例題：偏差値

問：ある大学の入試偏差値が55であったとする．入試結果が正規分布に従うと仮定したときに，上位何%までが合格圏内と言えるかを答えよ（小数点第1位までの値で答えよ）

答：偏差値の55は，平均が50・標準偏差が10のときの値である．Pythonを用いて，平均50・標準偏差10で，55の下側確率を求めると，69.146%とでるから，上位30.8%の受験生までが合格圏内といえる．


正規分布に近いか？：歪度(わいど, skewness)

- 分布のゆがみ度（非対称度）を示す
- $E(X - \mu)^3 / \sigma^3$ で定義され、3次のモーメント $E(X^3)$ に関連した値である
- 正規分布の場合、歪度は0となる→0に近いかで正規分布に近いかわかる
- Pythonでは `scipy.stats.skew()` 関数で求めることができる



正規分布に近いか？：尖度(せんど, kurtosis)

- 分布のとんがり度を示す
- $E(X - \mu)^4 / \sigma^4$ で定義され、4次のモーメント $E(X^4)$ に関連した値である
- 正規分布の場合、尖度は0となる→0に近いかで正規分布に近いかわかる
- Pythonでは `scipy.stats.kurtosis()` 関数で求めることができる



例題

（第2回の演習でも使用した）次のセルにある20戸の農家データを使って以下の問いに答えよ

問：販売金額の(1)歪度と(2)尖度，耕地面積の(3)歪度と(4)尖度を求めよ

- 解答は，演習用ノートブックを参照