

情報数学III

第5回：統計的推定の考え方，母集団と標本分布

鈴木源吾

前回の復習

1. さまざまな確率分布

- 一様分布
- 二項分布
- 正規分布
- ポアソン分布

2. 正規分布の復習

- 正規分布の性質

3. 確率分布の標準化，歪度，尖度

- 標準化
- 歪度・尖度

今回のトピック

1. 推測統計学

- 母集団と標本
- 推測統計学でできること

2. 標本分布

- 標本分布とは？
- 標本分布のばらつき（標準誤差）

教科書：第5部 第1-2章，第3章の一部（標本平均・標準誤差）

1. 推測統計学

推測統計学とは？

データの全体がわからないとき，その一部のデータから，データ全体のいろいろな特性について推測する統計学分野

- データの全体を**母集団**と呼ぶ
- 母集団からとったデータの一部を**標本**（サンプル）と呼ぶ
- 母集団から標本を取り出すことを**標本抽出**（サンプリング）と呼ぶ
- 母集団の確率分布を決定する特性を**母数**（パラメータ）と呼ぶ
（例：平均・分散・比率）

サンプリングは「**無作為**」であることが重要

- 母集団の1つ1つの要素を，すべて等しい確率で選ぶ選び方を**無作為抽出**と呼ぶ
（または，単純ランダムサンプリング）


参考：パラメトリック・ノンパラメトリックなモデル

- モデル：観測したデータを生み出す確率的な過程を簡潔に記述したもの（教科書）
- パラメトリックなモデル：母集団について特定の確率分布を仮定するモデル
 - 確率分布があり，パラメータ（母数）がある
 - 前ページは，パラメトリックである前提がある
- ノンパラメトリックなモデル：母集団について特定の確率分布を仮定しないモデル
 - ノンパラメトリックな場合も，それに適した統計手法がある
(参考書：入門統計学)

母集団と標本

例えば，テントウムシの体長を知りたいとする

- 世の中のすべてのテントウムシの体長を測ることはできない
- 我々は，その一部の体長を測って，世の中のテントウムシの体長を推測する



推測統計学でできること

どんな推測を行っていくのか？

最も基本的な推測としては、

- 「**標本**」の統計量（平均・分散など）から、「**母集団**」を特徴づける母数（パラメータ）をどう見積もれるのか？

がある．これを**点推定**と呼ぶ

推測統計学でできること（次回以降）

さらに次回以降では以下のような推測を行う

1. 区間推定

- 母数の範囲を確率的に表す手法
- 例：〇〇という品種の生育日数は95%の確率で10～15日の間に入る

2. 差の検定

- 母集団Aと母集団Bの母数の間に差があるかないかを確率的に判定する手法
- 例：農薬を使う前と後の害虫の数の平均の比較（差がある？ない？）
- 例：都市と農村での意識のばらつきの差

2. 標本分布

標本分布の学習にあたって

教科書にはあまり記述がないが、重要なので丁寧に説明する
(参考書「入門統計学」には記載あり)

少しわかりづらい → 統計学の入り口だが難関


標本抽出について

↓再掲

「母集団から標本を取り出すことを**標本抽出**（サンプリング）と呼ぶ」

標本抽出では，以下のような状況が想定されている．

やりたいこと：標本の平均を求めて，母平均を推定したい



標本サイズと標本数

2つの数字を以下のように区別する（重要）

3匹：標本サイズ（＝標本に含まれるデータの数）


10回：標本数（＝標本の数）

注意：標本抽出において、標本サイズは一定である

- 標本毎にサイズが違うことはない


標本サイズと誤差

- 標本サイズが大きくなると、標本の平均（標本平均と呼ぶ）は母平均に近づく



「標本の平均」の分布？

- 何度も標本を抽出して、標本の平均をヒストグラムにしたらどうなるか？




標本分布

- 前のページから，標本平均は確率変数と考えられる
- **標本に関する統計量に関する確率分布を，標本分布と呼ぶ**
 - 平均以外の統計量についても考えることができる
 - しかし，今後の話は，主に「平均」に関する議論であるとする
- 標本サイズは，固定の値である（前ページでは2）
- 母集団分布＋統計量の種類＋標本サイズで標本分布は（理論的に）決まる

標本サイズと標本分布のバラツキ


- 標本サイズが大きい場合→誤差が小さくなりやすい→標本分布の分散が小さい
- 標本サイズが小さい場合→誤差が大きくなりやすい→標本分布の分散が大きい



標準誤差 (Standard Error)


前ページまで→「標本サイズが大きくなると、標本平均のばらつきは小さくなる」

- 「**標本分布の標準偏差**」を誤差の指標とみなし、
標準誤差 (Standard Error) と呼ぶ
- 下図の σ (シグマ) が標準誤差



標準誤差（補足）

- 正規分布の場合， ± 1 標準偏差の位置でグラフの傾きが変わる（＝標準誤差の位置）
- （実際にはありえないが）極端な例として，標本サイズが母集団と等しくなると…
 - 標本分布の平均は母平均に一致し（1cm）
 - 標準偏差0で誤差も0



標準誤差の大きさは？（正規母集団）

母集団が、正規分布 $N(\mu, \sigma^2)$ に従う場合、

標本サイズ n で標本抽出したときの、標本平均の標本分布は、 $N(\mu, \sigma^2/n)$ となる

→ 標準誤差は $\sigma/\sqrt{n}$. つまり、元の標準偏差の $1/\sqrt{n}$
(分散だと $1/n$)

→ 標本サイズを4倍にすれば、標準誤差は $1/2$ になる

補足：**母集団が正規分布でなくても**、標本平均の分散 σ^2/n という式は成り立つ
(詳細は教科書p.261を参照．分散や平均の定義を利用して証明できる)

標準誤差の大きさは？（一般の場合）

正規分布に限らず，母集団がどのような分布であっても，ある程度の条件のもとで，
標本サイズ n が大きいとき，標本平均の分布は，平均 μ ，分散 σ^2/n の正規分布 $N(\mu, \sigma^2/n)$ に近づく

という性質がある．これは 中心極限定理 による（※詳細は次回以降に扱う予定）．

- これにより，母集団が非正規分布であっても，標本平均の分布を正規分布とみなして解析できる 理論的な根拠が得られる．

注意：ただし，中心極限定理による「正規分布への近づき方」は，標本サイズ n や母集団の分布形状に依存する．

特に，母集団が極端に歪んでいる場合や外れ値を多く含む場合は， n がかなり大きくないと正規分布に近づかない．

例題と演習：Pythonで標本分布を体験してみる

演習用ノートブックを参照

- 例題：標本サイズ4・標本数30で正規分布から標本抽出し，標本平均のヒストグラム（標本分布）を描く
- 演習：標本サイズを16にして同じ手順を行い，標本分布の分散の変化を確認する
 - 理論的には分散は何分の1になるか？