

情報数学III

第6回：統計的推定：母平均・母分散の推定，確率分布

鈴木源吾

シラバスでは，区間推定が入っていたが次回に回す

前回の復習

1. 推測統計学

- 母集団と標本
- 推測統計学でできること

2. 標本分布

- 標本分布とは？
- 標本分布のばらつき（標準誤差）

今回のトピック

1. 点推定と不偏推定量
 - 点推定
 - 不偏分散と不偏推定量
2. 正規母集団から派生した確率分布
 - χ^2 分布
 - t 分布
 - F 分布

教科書：第5部 第3-5章

1. 点推定と不偏推定量

点推定

↓ 前回資料より．今回は点推定について，詳しく説明する．

どんな推測を行っていくのか？

最も基本的な推測としては，

- 「**標本**」の統計量（平均・分散など）から，「**母集団**」を特徴づける母数（パラメータ）をどう見積もれるのか？

がある．これを**点推定**と呼ぶ

点推定：標本の統計量→母集団の統計量はわかる？

例えば，テントウムシ10匹の体長のデータが標本としてあるとする．そこから

- 体長の平均
- 体長の分散（標準偏差）

は容易に計算することができる

そのデータから，テントウムシ全体（母集団）の体長の平均と分散は推定できるか？

→ 最も素朴な考え方は，それをそのまま母集団の平均と分散としてしまう・・・

→ **重要：これは，平均では許されるが，分散では許されない！**

母平均の点推定と「推定量」

まず，テントウムシ10匹の標本の母平均の推定を考えよう．以下の考え方である．

- 標本に含まれる10匹の体長の平均を求める
- その値で，母平均の値が推定できた

このように，点推定をするときには，それに使う統計量がある．ここでは，**「標本平均」という統計量を用いて母平均を推定**している

このように，推定に用いられる統計量を**推定量**と呼ぶ

(少し分かりづらい．推定量とは推定に使う計算方法と考える方が直感的かも)

用語の整理

- 母集団の平均を**母平均**と呼び、 μ （ミュー）で表す
- 母集団の分散を**母分散**と呼び、 σ^2 （シグマにじょう）で表す
 - 同様に、母標準偏差が σ
- 標本の平均を**標本平均**と呼び、 $\bar{x}$ （エックスバー）で表す
- 標本の分散を**標本分散**と呼び、 s^2 で表す
 - 同様に、標本標準偏差が s
- 平均や標準偏差などの確率分布を決定する値を**パラメータ**（母数）と呼ぶ

ルール

- 母集団から得られる統計量 → 母ほげほげ ギリシャ文字
- 標本から得られる統計量 → 標本ほげほげ アルファベット

標本平均と母平均

- 標本平均がわかったからと言って、母平均がわかるものではない
- しかし、標本サイズを多くしていけば、母平均に近づくことが知られている
→ **大数（たいすう）の法則**
- 直感的な言い方をすると「**経験的な平均は、理論的な平均に近づく**」
 - 例：サイコロを振り続けると、1が出る数の割合は $1/6$ に近づいていく
 - 「標本の大きさが大きくなるにつれて、標本平均が母平均に近づく」
(教科書 p.266)
- これが、**標本平均を使って母平均を推定してもよい根拠**となっている
 - 本当は標本サイズが大きいといけませんが・・・

母分散の点推定：標本分散と母分散

実は、**標本分散は母分散より小さくなる傾向がある！**（重要）

→ 標本のばらつきは母集団のばらつきよりも小さく見積もられている

なぜか？ → 標本分散の計算に、標本平均を使っていることに起因する

- 標本平均を使うと偏差平方和が減る方向になる（イメージは下図）
 - 偏差＝平均からの隔たり（距離）

では母分散をどう見積もるか？

- 標本分散式の分母を少し小さくし、分散を大きめに見積ることで、真の母分散の値に近づけることができる
- 分母を n の代わりに $n - 1$ で置き換える（ $n - 1$ は**自由度**と呼ばれる）
 - 10個のデータで約1割の見積もりのずれが生じることになる（逆に100個もあればずれは大きくない．参考書では大標本を30個程度としている）

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

→ この値は、標本による計算によるバイアス（偏り）がないという意味で**不偏分散**と呼ばれる（英語でunbiased variance）．教科書では u^2 で表記

注意： σ の上にあるハットは、 σ の推定量を表すのに使うが、 $\hat{\sigma}^2$ は慣例的に不偏分散を表すのに使われる

自由度がn-1になる理由

不偏分散では標本分散の分母のnをn-1で置き換えた．なぜ，n-1でよいか？

- 前に説明した図（下図）を思い出そう．原因は，標本平均を都合よく選んでしまっていることにあった
- よって，標本平均自体もばらつくことを考慮に入ればよい
- 標本平均のばらつき → 標本平均の分散（誤差分散） $\frac{\sigma^2}{n}$

自由度が $n-1$ になる理由

厳密性に欠けるが、直感的には以下の計算になる（参考書より）。

なぜ自由度と呼ぶのか？

自由度とは，直感的には「本質的なデータの数」である

- 本当のデータが n 個あるんだけど，自由に動けるデータの数は $n-1$ 個である
- 自由に動けるデータが減る理由は，（標本）平均が決まっていることによる束縛

1. a, b, c という3つの変数の平均 $(a+b+c)/3$ を考える
2. 平均が決まっていない場合→ abc いずれも自由に値を取れる（自由度=3）
3. 平均が決まっている場合→ abc のうち2つしか自由に値は取れない（自由度= $n-1=2$ ）

例： $(5+10+\square)/3=10$ なら， $\square$ は15しかない

色々な自由度

- 今回の不偏分散では自由度が $n-1$ だったが、様々な統計量ではそうとは限らない
 - それは、統計量の計算に使う制約条件の数で決まる
 - 標本平均は、その制約条件の一種
 - 平均以外にも、標本データを使った計算式があれば制約条件となる
 - 不偏分散では、一つの制約条件しか使っていないから、 $n-1$ でよい
 - x と y などのように、2つの標本平均使う統計量の自由度は $n-2$ になるときがある
- 様々な統計分析を行うときに、出てくる（今の所は不偏分散がわかればよい）

不偏推定量

- 不偏分散のような，標本による計算のバイアスがなく，標本のデータを使って母集団の統計量を推定できる値を**不偏推定量**と呼ぶ
- 数学的には，「**推定量の期待値（平均）が，推定しようとしている母数の値と一致するとき**」その推定量は不偏推定量であると呼ぶ（不偏性があるとも言う）
- 標本平均は，母平均を推定するための，不偏推定量である
- 不偏分散は，母分散を推定するための，不偏推定量である
- 不偏分散の平方根は，母標準偏差を推定するための，不偏推定量ではない
 - 厳密には，母標準偏差より少し小さく見積もってしまうため
 - Pythonのnumpyによる計算（`np.std(x, ddof=1)`）は不偏分散の平方根を求める

平均のまとめ

全部同じ式となる（標本平均は母平均の不偏推定量である）

- 標本平均

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

- 母平均

$$\mu = \frac{\sum_{i=1}^n x_i}{n}$$

- 不偏平均

$$\hat{\mu} = \frac{\sum_{i=1}^n x_i}{n}$$

分散のまとめ

- 標本分散

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

- 母分散

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n}$$

- 不偏分散（教科書では u^2 ）

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

標準偏差のまとめ

- 標本標準偏差

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}}$$

- 母標準偏差

$$\sigma = \sqrt{\frac{\sum_{i=1}^n (x_i - \mu)^2}{n}}$$

- 不偏標準偏差（簡易版）（教科書では u ）

$$\hat{\sigma} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

2. 正規母集団から派生した確率分布

χ^2 分布(chi-squared distribution)

χ^2 分布とは？ → χ^2 値が従う確率分布(χ^2 検定で使われることが有名)

では、 χ^2 値とは？

- 下図の n を、 χ^2 分布の自由度(degree of freedom, df と略す)と呼ぶ.
- 自由度は、 χ^2 分布の唯一のパラメータ (母数) である

自由度と χ^2 分布の形状

自由度によって χ^2 分布の確率密度関数の形は変わる

χ^2 値と分散

χ^2 分布は，以下のような形で定義された：

$$\chi^2 = z_1^2 + z_2^2 + \cdots + z_n^2$$

この式は，各 z_i が「平均0からどれだけ離れているか」の二乗を足し合わせたもの。

つまり，**ばらつきを測る量**であり、**分散に近い構造**を持っている。

ただし，分散は通常こう定義される： $\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$

→ 分母で割る前の「ばらつきの合計」の部分が， χ^2 分布の形とよく似ている！

χ^2 値と分散の関係

正規母集団(母平均 μ , 母分散 σ^2)のもとで標本 $x_1, \dots, x_n$ を抽出する

このとき、**母平均 μ が未知なので、標本平均 $\bar{x}$ を用いて**以下の量を考える：

$$\frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2$$

この量は、**自由度 (n - 1) の χ^2 分布** に従う：

$$\frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{\sigma} \right)^2 \sim \chi_{n-1}^2$$

標本平均 $\bar{x}$ を使うことで、全体のばらつきの中に**1つの制約**が入り、
独立な情報が $(n - 1)$ 個に減る → それが自由度 $(n - 1)$

χ^2 値と不偏分散の関係

不偏分散（教科書p.270では u^2 ）の定義は以下だった：

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

前ページの式と結びつけると：

$$(n-1)\hat{\sigma}^2 = \chi_{n-1}^2 \cdot \sigma^2$$

$$\frac{(n-1)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-1}^2$$

不偏分散と χ^2 値は、**母分散を用いた比率**の形で結びついており、推定や検定で χ^2 分布を使う根拠になる。

χ^2 値は「食い違い指数」

観測データが、期待される理論値とどの程度「食い違っているか」を測る指標
→ これを確率的に評価できるのが χ^2 統計量 → χ^2 分布に従う

- 「食い違い指数」とも呼ばれる (discrepancy index)
- 実際には、**観測値と期待値のズレ**を二乗して足し合わせたもの：

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$$

- → **ユークリッド距離（二乗和）に似ており、ズレの大きさを測る量**

用途

- 適合度検定（例：血液型の分布 → B型が多い？）
- 独立性検定（例：男女と喫煙の関係） → 教科書第6部第3章

標本平均を標準化したらどんな分布？

標本平均 $\bar{x}$ は母平均 μ の周りにばらつく．その標準偏差は $\sigma/\sqrt{n}$ だったので，以下のように標準化できる（ σ は母標準偏差）：

$$z = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$$

でも，実際には σ は未知 → 標本から計算した不偏分散 $\hat{\sigma}^2$ を使って推定する．

$$t = \frac{\bar{x} - \mu}{\hat{\sigma}/\sqrt{n}}$$

これは標準正規分布とは少し違った分布となる（次ページ）

※ 教科書では確率変数として $\bar{X}, T$ などの **大文字** を使っている場合がある

t値とt分布

この標準化変量（標準正規分布に従う）の代用品を**準標準化変量**と呼ぶ

$$t_{\bar{x}} = \frac{\bar{x} - \mu}{\hat{\sigma} / \sqrt{n}}$$

- 標準化変量をz値と呼んだのに対して、**t値**と呼ばれる
- 標準化変量の母標準偏差を不偏標準偏差に置き換えたものである
- この変換を**準標準化**（またはスチューデント化）と呼ぶ

→ この統計量に従うのが、**t分布**！

t分布の数学的定義と構造

実はこの t分布は、次のような理論的構造を持っている（教科書p.285）：

- $X \sim \mathcal{N}(0, 1)$ ：標準正規分布
- $Y \sim \chi_k^2$ ：自由度 (k) のカイ二乗分布
- X, Y は独立

このとき、次のような変量：

$$T = \frac{X}{\sqrt{Y/k}} \sim t(k)$$

を「自由度kの**t分布**」と呼ぶ ($t(k)$ と表記する)

正規母集団からの無作為標本（標本サイズ n ）から計算されたt値は $t(n - 1)$ に従う

t分布

このt値が従う分布を発見したのが、ウィリアム・ゴセット（1876-1937）である

- スチューデント化のStudentとはゴセットのペンネームである
- t分布のtはStudentの2文字目のtであると言われている
（sが既に標準偏差に使われていたから）

t 分布の形状

自由度によってグラフの形は変わる

F分布 (F-distribution)

F分布とは？ → F値が従う確率分布（Fは統計学者フィッシャーの頭文字）

- 用途：等分散の検定や分散分析などで利用
- 特徴：2つの母集団から抽出した標本から計算した統計量
 - 2つの自由度によって分布形が変化
 - 2つの母集団の分散が同じかの判定に使える
- 特徴：t値と関係が深い

F値とは？

分散の比に関する値

F分布の特徴

- 母数は2つの自由度（のみ）
- 期待値（平均）（ただし， $\nu_2 > 2$ ） $\rightarrow \nu_2$ が大きいと1に近づく

$$E(F) = \frac{\nu_2}{\nu_2 - 2}$$

- 分散（ただし， $\nu_2 > 4$ ）

$$V(F) = \frac{2\nu_2^2(\nu_1 + \nu_2 - 2)}{\nu_1(\nu_2 - 2)^2(\nu_2 - 4)}$$

2つの自由度とF分布の形状
