

情報数学III

第7回：区間推定

鈴木源吾

前回の復習

1. 点推定と不偏推定量
 - 点推定
 - 不偏分散と不偏推定量
2. 正規母集団から派生した確率分布
 - χ^2 分布
 - t 分布
 - F 分布

今回のトピック

1. 信頼区間の推定の基礎
 - 中心極限定理
 - 信頼区間の推定とは
2. 正規分布による区間推定: 母分散が既知の場合
 - 正規分布による区間推定
3. t分布による区間推定: 母分散が未知の場合
 - t分布とは
 - t分布による区間推定
4. 母分散の区間推定

教科書：第5部 第6章

1. 信頼区間の推定の基礎

標本分布はどのような確率分布に従うのか？

第5回の講義の図では、(標本平均の) 標本分布は、真の平均に近い標本ほど多くあるから、正規分布のようになるという説明をした

中心極限定理(central limit theorem)

このことを数学的に証明しているのが、以下の定理である

中心極限定理

母集団分布の平均，分散を μ, σ^2 とするときに，**母集団分布が何であっても**，標本の大きさ n が十分大きいときは，標本の平均は， $N(\mu, \sigma^2/n)$ に従う

- $N(\mu, \sigma^2/n)$ は，平均が μ で，分散が σ^2/n の正規分布を表す
- 以前も説明したが，分散が $1/n$ になることが重要（標本サイズが大きければ分散は小さい）

中心極限定理のイメージ

「母集団分布が何であっても」というのが重要

→ これを根拠に，正規分布を使った統計分析を行える

応用：2項分布の極限が正規分布

中心極限定理を適用すると、「2項分布の極限が正規分布であること」を導くことができる

理由

- 2項分布 $B(n, p)$ における成功回数は、それぞれ $B(1, p)$ に従う n 個の確率変数の和となっている
 - $B(n, p)$ ：成功確率 p ， n 回の試行で成功する回数の確率分布
 - $B(1, p)$ ：成功確率 p ，1回の試行で成功する回数の確率分布
- n 個の確率変数の和（平均の n 倍）は，平均と同様に正規分布に近づいていく

信頼区間の推定とは？

標本分布が正規分布となるということは，例えば，テントウムシの標本を1つ作って，その平均が1cmだったとすると，それを母平均であると推定して（大数の法則），標本分布が下のように推定できる

- 標本平均から推定した母平均を真ん中においた正規分布

信頼区間の推定とは？

とすると，正規分布から，1cmを中心として左右合計で確率95%の範囲はわかるから，その範囲に入るようなテントウムシの体長は，「95%の確率で推定できる体長である」と言って良いのではないか？

- テントウムシの体長は，95%の確率でaからbの値をとる

信頼区間とその用語

- この区間を**信頼区間**と呼ぶ
- 区間に入る確率を，**信頼係数**(confidence coefficient)と呼ぶ
- 区間の両端を，**信頼限界**と呼び，2つをそれぞれ**上側**・**下側**と区別する

信頼係数の意味：数学的により正確な説明

2. 正規分布による区間推定: 母分散が既知の場合

信頼区間の求め方

ここからは、どのように信頼区間を求めるかを述べる

これは、2つに分類することができる

1. 母分散が既知，もしくは大標本の場合 → Topic 2で説明
2. 母分散が未知，かつ小標本の場合 → Topic 3で説明

これは、「標本から分散を推定するときに，標本サイズが小さいときは，不偏分散を考える必要がある」という前回の話に起因する（重要）

母分散が既知もしくは大標本の場合

- 今、母平均の推定をしようとしているのに、母分散が既知というのは、前提としては、ほぼあり得ない話ではある
- しかし、標本サイズが大きい場合（目安30以上）は、この方法を使ってよいから、意味はある

この場合は、

- 標本平均を母平均として推定し、
- 母分散が既知であれば、それをそのまま使い
- 標本サイズが大きければ、標本分散を母分散として推定して

正規分布を考えればよい

信頼限界の求め方

標準正規分布からの平行移動と伸縮という考え方で，上側・下側の信頼限界を求めることができる

95%の信頼係数で考えよう．下図のような対応になる． a, b の値を求めたい

- まず，平均については，右側は0であり，左側は標本平均を真ん中においている

信頼限界の求め方

- 次に標準偏差を考えると、右側は1であるが、左側は、標本分布の標準偏差（標準誤差）であるから、前回やったように $\sigma/\sqrt{n}$ である
- 次に、標準正規分布の右側の「?」の位置はどうなるだろう．97.5%点（パーセント点と呼ぶ）を求めることになる．Pythonのppf関数を使うと、1.96とわかる

信頼限界の求め方

- 下図のように左右の比例関係から、 $a \cdot b$ の位置が決まる
- よって、求める信頼区間は、

$$\bar{x} - 1.96 \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{x} + 1.96 \frac{\sigma}{\sqrt{n}}$$

信頼係数と区間の関係

標準化を利用した信頼区間の求め方

変数を標準化（平均引いて標準偏差で割る）し，標準正規分布に帰着させ信頼区間を求めることもできる．信頼係数95%の場合を考えると，

topic 2 例題

ある園芸農家が、母の日に向けて出荷を控えたカーネーション16本の蕾（つぼみ）の直径を調べたところ、平均で10.0mmだった．この園芸農家の栽培しているカーネーションの蕾の平均直径を信頼係数95%で推定せよ．ただし，母分散は $36.0(mm^2)$ であるとわかっているとする．

→ 演習用ノートブック参照

topic 2 演習

ある島に調査に行って，そこに自生しているスギの中から無作為に100本を選び，胸高周囲（成人の胸の高さでの幹周り）を観測したところ，標本平均が2.0m，標本分散が $1.0(m^2)$ だった．この島のスギの胸高周囲の母平均に対する信頼区間を信頼係数95%で推定せよ．標本サイズが100と十分大きいので，標準正規分布を使用せよ．

→ 演習用ノートブック参照

3. t分布による区間推定: 母分散が未知の場合

母分散がわからなかったどうするか？

代わりに不偏分散を使えばよい？

→ 不偏分散を使って同様に正規分布を使えば良い？ → **No!**

母分散がわかった場合 → 標準化変量が標準正規分布に従った

母分散がわからない場合

→ 不偏分散を使った標準化変量に相当する変量に従う「t分布」を使う

t 分布の信頼区間

t 分布による区間推定

- 分布が変わるが、やり方は正規分布のときと同じである
- 自由度が「標本サイズ-1」であるt分布を用いる
(自由度の略称としてdf (degree of freedom) を用いるときがある)

t 分布による区間推定

topic 3 例題

ある日，ある酪農家が，搾乳中のホルスタイン5頭の乳量を調べたら，1頭あたりの平均乳量は22.1リットル，標本標準偏差は6.5だった．この農家が飼養しているホルスタインの1頭あたりの乳量（/日）を，信頼係数95%で推定せよ．

→ 演習用ノートブック参照

topic 3 演習

以前の演習でも使った農家データから，この地域の農家の販売金額の母平均に対する信頼区間を信頼係数95%で推定せよ．

→ 演習用ノートブック参照

4. 母分散の区間推定

前回の復習： χ^2 値と不偏分散の関係

前回 χ^2 値について学んだ．不偏分散と密接な関係があり，以下の式が成り立った．

$$(n - 1)\hat{\sigma}^2 = \chi_{n-1}^2 \cdot \sigma^2$$

$$\frac{(n - 1)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-1}^2$$

これを，以下のように変形すると，母分散の信頼区間の推定に活用できる．

$$\sigma^2 = (n - 1)\hat{\sigma}^2 / \chi_{(n-1)}^2$$

母分散の信頼区間の推定

例題：母分散の信頼区間の推定

Aという種のテントウムシを5匹採集した．それらの体長は，小さい順に5mm, 8mm, 10mm, 11mm, 15mm だった．このテントウムシの体長の母分散に対する信頼区間を信頼係数95%で推定せよ

→ 演習用ノートブック参照

Topic 4 演習

ある農家の10年間の平均農業所得率の不偏標準偏差は5%だった．この農家の経営上のリスク，つまり農業所得率の母標準偏差が入ると考えられる信頼区間を信頼係数90%で推定せよ

ヒント

- データが10年分あるから，標本サイズは10
- 分散の区間推定を行って，平方根をとればよい

→ 演習用ノートブック参照