

情報数学III

第9回 統計的仮説検定：平均値の差の検定，分割表の検定

鈴木源吾

前回の復習

1. 検定の概要

- 検定とは?
- 検定の手順

2. 母平均の検定

- 母平均の検定
- 標準正規分布やt分布の利用

3. 統計的過誤と検出力

- 統計的過誤
- 有意水準と検出力

今回のトピック

1. 2群の平均の差の検定の概要
 - 2群の平均の差の検定とは？
 - 対応関係の有無とは？
2. 2群の平均の差の検定
 - 対応のない2群の差の検定
 - 対応のある2群の差の検定
3. 関連した話題
 - 等分散の検定
 - 両側検定と片側検定

教科書：第6部 第2・3章

1. 2群の平均の差の検定の概要


2群の平均の差の検定とは？

実験結果を使用前・使用後などの2グループ（群）に分け，それらの「**平均の差**が母集団においてもあるとってよいかどうか」，を統計学的に検討する手法

使用する例


- 肥料を使う前と，使った後での成長速度の差
- 農村と都市とで，農業所得の差
- ダイエット薬を飲む前と，飲んだ後で体重に差があるか？

最もよく使われる検定手法



対応関係のある・なしとは？

平均の差の検定は，対応関係のある・なしで手法が異なる




対応関係の例

肥料の効果の有無で対応関係を示す．計算方法と自由度に影響する

対応のない2群

2つの畑で1回で実験

肥料なし 肥料あり



平均とる 平均とる

差を調べる

2倍時間がかかる
(実験によっては2年かかるかも!)


同じ場所だから
肥料以外の条件
は同じ

8個のデータに
関する分析
→自由度に影響

対応のある2群

1つの畑で時間差で2回実験

肥料なし 肥料あり



平均
調べる

4個のデータに
関する分析
→自由度に影響

2群の平均の差の検定の概要

手順は前回述べた検定の手順と同じ


1. 帰無仮説の設定
2. 検定統計量の計算
3. 確率の計算
4. 仮説の判定

対応関係のある・なしによって、使用する検定統計量が変わる

帰無仮説の設定

差があることを示したい → その反対である「差がない」ことを帰無仮説とする
2つの母集団の平均をそれぞれ, μ_1, μ_2 とすると, 帰無仮説 $H_0 : \mu_1 = \mu_2$

- これは, 対応関係のある・なしに関わらず共通




2. 2群の平均の差の検定

検定統計量をどうするか？

↓ この図が重要．対応のある・なしで変わる


別の例：全く異なる学生の2群のテスト結果 / 同じ学生群の2回のテスト結果



対応のない2群の検定統計量

標本平均の差 $\bar{x}_1 - \bar{x}_2$ の標本分布を考える！→これで検定する

対応のない2群



例) 対応なしとする

ある植物の成長速度 (cm/日)

肥料なし	肥料あり
0.8	1.1
0.7	1.5
1.0	1.0
0.5	1.6
0.6	1.3
標本平均 $\bar{x}$	0.72 1.30


差をとる

-0.58

この例は教科書と同じだが、ここでは教科書とは違い対応がないと仮定する

標本平均の差の分布はどうなる？

証明は省略．分散が和になるのがポイント（差の分散は直感的にも大きくなる）



検定統計量：対応なし，母分散既知または大標本

- 検定に使う標準化変量が検定統計量だった．母分散既知または大標本の場合

(復習) 標本平均
の標準化変量 $z_{\bar{x}} = \frac{\bar{x} - \mu}{\sigma_{\bar{x}}}$

標本平均の差
の標準化変量

$$z_{\bar{x}_1 - \bar{x}_2} = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sigma_{\bar{x}_1 - \bar{x}_2}}$$

帰無仮説の下では
ゼロと期待される

2つの群の分散が等しい
という仮定を置く

バラツキは和になる

$$\sqrt{\sigma_{\bar{x}_1}^2 + \sigma_{\bar{x}_2}^2} = \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} = \sqrt{\sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}$$

注意：等分散の仮定は，必ずしも
成り立つとは限らない．成り立つ
かの確認方法・成り立たないとき
の手法はある（後述）

検定統計量：対応なし，母分散既知または大標本


前ページの式をまとめると，検定統計量として，以下の値が使える

$$z_{\bar{x}_1 - \bar{x}_2} = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

- 2つの母分散が既知の場合→不偏分散を考えなくてよい場合
- 大標本の場合も，標本分散を母分散の近似値として使えた
- この場合は，正規分布で検定してよかった
 - 正規分布なので検定時，自由度は問題にならない

仮説の検定（z検定）

- 前ページに作った検定統計量で普通にz検定（正規分布の検定）を行えばよい



検定統計量：対応なし，母分散未知かつ小標本

- 小標本の場合は，不偏分散を使わないといけなかった → t分布
- よって，前にやった母分散を不偏分散に変えるだけでよい

$$t_{\bar{x}_1 - \bar{x}_2} = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\hat{\sigma}_{\bar{x}_1 - \bar{x}_2}^2}} = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\hat{\sigma}^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

2つの標本のサイズが異なる場合は，2つの標本分散を自由度で加重平均したものを使う

$$\frac{(n_1 - 1)\hat{\sigma}_1^2 + (n_2 - 1)\hat{\sigma}_2^2}{(n_1 - 1) + (n_2 - 1)}$$

2群の標本サイズが同じ場合は，以下のように単純になる


$$t_{\bar{x}_1 - \bar{x}_2} = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{\hat{\sigma}_1^2 + \hat{\sigma}_2^2}{n}}} = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2 + s_2^2}{n - 1}}}$$

t分布なので，検定時，自由度によって限界値が変わる

仮説の検定 (t検定)

重要：自由度は
 $df = (n_1 - 1) + (n_2 - 1)$

両群の標本サイズが等
しければ
 $df = 2n - 2$



帰無仮説を受容

これぐらいの差は偶然でもよくあるので、異なる母集団から抽出した平均とはいえない「この標本からは μ_1 と μ_2 の差は有意とはいえない」


帰無仮説を棄却

滅多にないほど大きな差なので、別の母集団から抽出した平均といえる「 μ_1 と μ_2 の差は統計的に有意といえる」

自由度について

- 平均の差をとる統計量を作るのに、実質的に $(n_1 - 1) + (n_2 - 1)$ 個のデータを使っている
- 2つの標本平均 $\bar{x}_1, \bar{x}_2$ が計算につかわれているから、1つずつ自由度が減っている

対応のない2群



例) 対応なしとする

ある植物の成長速度 (cm/日)

肥料なし	肥料あり
0.8	1.1
0.7	1.5
1.0	1.0
0.5	1.6
0.6	1.3
標本平均 $\bar{x}$	0.72 1.30

差をとる

-0.58

この例は教科書と同じだが、ここでは教科書とは違い対応がないと仮定する

例題1：アルゴリズムの性能比較

「30個のデータセットを無作為に2つのグループに分け、それぞれにアルゴリズムAまたはBを適用し、処理時間（ミリ秒）を測定した。」


- データセット1～15：アルゴリズムA適用
- データセット16～30：アルゴリズムB適用

アルゴリズムAとアルゴリズムBの平均的な処理時間に有意な差があるかどうかを，有意水準5%で検定せよ．

→ ノートブック参照

注意：2つのグループのデータセットに対応はないので，対応のないt検定を用いる．

対応のある2群の差の検定



例) 対応あり

ある植物の成長速度 (cm/日)

肥料なし	肥料あり
0.8	1.1
0.7	1.5
1.0	1.0
0.5	1.6
0.6	1.3

差をとる. d_i とする

差
-0.3
-0.8
0.0
-1.1
-0.7

この値が分布
すること検
定に利用

差の平均

-0.58

検定統計量：対応あり，母分散未知かつ小標本

- 小標本でt検定を使う場合のみ説明する
- 大標本の場合は，同様に標準正規分布を利用すればできる
- 検定統計量さえわかれば，あとはt分布を使って検定するだけ

$\bar{d}$ の真の値なので，帰無仮説ではゼロとなることが期待される

検定統計量：
(差の平均 $\bar{d}$ の準標準化変量)

$$t_{\bar{d}} = \frac{\bar{d} - \mu}{\hat{\sigma}_{\bar{d}}} = \frac{\bar{d} - \mu}{\hat{\sigma}/\sqrt{n}} \rightarrow \frac{\bar{d}}{\hat{\sigma}_{\bar{d}}} = \frac{\bar{d}}{\hat{\sigma}/\sqrt{n}}$$


差dの不偏標準偏差

個体差に相当する

$$\hat{\sigma} = \sqrt{\frac{\sum_{i=1}^n (d_i - \bar{d})^2}{n - 1}}$$

自由度について

- 対応のある2群の差のt検定の自由度dfはn-1となる
- 差の標本分布を考えている．差の標本のデータ数はn個
- 差のデータはn個だが，その標本平均は使われているので，自由度が1減る



例) 対応あり

ある植物の成長速度 (cm/日)

肥料なし	肥料あり	差
0.8	1.1	-0.3
0.7	1.5	-0.8
1.0	1.0	0.0
0.5	1.6	-1.1
0.6	1.3	-0.7

差をとる. d_i とする

差の平均

-0.58

この値が分布
すること検
定に利用

例題2：システム改善前後の処理性能の比較

ある計算システムに対して最適化（例えばソフトウェア更新やハードウェアチューニング）を行い，改善前後の処理効率（単位処理あたりのリソース消費の少なさなど）を5台の装置で測定した．

システムの最適化処理により，処理性能が有意に変化したと言えるか．有意水準5%で検定せよ

注意：同じ装置の最適化前後なので，対応のあるt検定を使う

→ ノートブック参照

2群が等分散でない場合どうする？

- 今述べた検定は、「2群の分散が等しい」という仮定を置いていた
- しかし、その仮定が成り立たない場合はどうするのか？

→ 「ウェルチの検定」という手法がある

教科書からのノートブックでは、ウェルチの検定を用いた計算方法が示されている。
教科書は、最初からウェルチの検定を使えば良い、というスタンスで書かれている。
(大きく結果は変わらないから、保守的に評価をしとく)

3. 関連した話題

等分散の検定

「対応のない」2群の平均の差の検定を行う場合、

- 分散が等しい仮定を置ける場合→z検定・t検定で可能
- 分散が等しくないとき→ウェルチの検定を使う


ということだった。では、標本から、その母集団の分散が等しいか・等しくないかを判定できないか？

→ **「等分散の検定」** を利用すれば良い

- t検定・z検定を行う前に、等分散の検定を実施すればよい

等分散の検定とは？

- 分散が等しいかどうかを検定する→下図は平均の差の検定と似た図



等分散の検定に使う道具：F分布


- F値は、2つの χ^2 値を対応する自由度で割って、**比を取ったものだった**
- χ^2 値は分散と関連する量だった → F分布を使える！
- 検定統計量はF値

$$F_{(v_1, v_2)} = \frac{\chi^2_{(v_1)}/v_1}{\chi^2_{(v_2)}/v_2} = \frac{\frac{v_1 \hat{\sigma}_1^2}{\sigma_1^2}/v_1}{\frac{v_2 \hat{\sigma}_2^2}{\sigma_2^2}/v_2} = \frac{\hat{\sigma}_1^2}{\hat{\sigma}_2^2} \quad \text{ただし, } \sigma_2^2 \leq \sigma_1^2$$

分散が等しいを帰無仮説
に置くから $\sigma_1^2 = \sigma_2^2$

この値が1よりもずっと
大きければ棄却


等分散の検定（F検定）のイメージ



等分散の検定：仮説の判定

限界値を上側確率5%の位置にとり，以下のように判定する

- 検定統計量（F値）が，限界値より大きい（p値は5%より小さい） → 棄却
 - 分散が等しいと言えないから，t検定ではなくウェルチの検定を使う
- 検定統計量（F値）が，限界値より小さい（p値は5%より大きい） → 受容
 - 分散が等しいとも等しくないとも言えないが，t検定を使って良いだろう




例題3：例題1で等分散の検定

例題1（アルゴリズムの性能比較）では，等分散を前提とした検定を行ったが．この2群について，有意水準5%で等分散の検定を行い，等分散を前提としてよいかを検証せよ．

→ ノートブック参照

両側検定と片側検定




片側検定が使える場面

- 片側検定の特徴：両側検定よりも帰無仮説を棄却しやすい
 - 自分の主張したい結論が示しやすくなる（注意：メリットではない）
- 片側検定が使える場面：
 - 検定統計量が分布の片側に来るとあらかじめわかっている場合
 - 反対側の判断に意味がない場合
 - 例）新旧の殺虫剤を使用した後の害虫数の差の検定
 - 新が殺した数 > 旧が殺した数 → 意味あり
 - 旧が殺した数 > 新が殺した数 → 興味なし → 片側の差しか意味がない
- 使える場面の状況を満たすことが明確でなければ、両側検定を使うべき
- 今後の演習や小テストでは、原則、両側検定を使う

χ^2 検定と F 検定は片側検定だけ

- χ^2 分布や F 分布のように左右対称ではなく、偏っている場合は、中央からはずれた領域が片側だけになる場合があるから、片側検定が適切である



演習：サーバ室温と処理時間の関係

ある学生が、サーバの室温が処理性能に与える影響を調べるために実験を行った。

サーバをそれぞれ室温 **15°C** と **20°C** に保った2つの部屋に設置し、同じ処理を複数台のサーバで実行した。各室温で7回ずつ実行し、それぞれの実行で **処理完了までにかかった時間（秒）** を記録した。

この実験結果に基づき、室温の違い（15°Cと20°C）が処理時間に影響を与えたといえるかを、有意水準5%で検定せよ。

注意：これは対応のある／なしのどちらだろうか？