

情報数学III

第10回 統計モデルと回帰分析

鈴木源吾

注意：統計モデルの具体例としての回帰分析を先に話す

前回の復習

1. 2群の平均の差の検定の概要
 - 2群の平均の差の検定とは？
 - 対応関係の有無とは？
2. 2群の平均の差の検定
 - 対応のない2群の差の検定
 - 対応のある2群の差の検定
3. 関連した話題
 - 等分散の検定
 - 両側検定と片側検定

今回のトピック

1. 統計モデルと回帰分析
2. 回帰分析とは
3. 回帰直線はどうやって決める？：最小二乗法
4. 係数の検定

教科書：第7部 第1, 2, 5章，第8部 第1章（すべて一部）

1. 統計モデルと回帰分析

統計モデルとは？

教科書によると、

- 「**数理モデル**とは、現象を数式で表したモデルのことです」(1-5節)
- 「数理モデルの中でも特に、確率的な表現を伴うモデルを、**確率モデル**と呼びます」(1-6節)
- 「確率モデルの構造を考えたとうえで、データに対して適合するようにパラメータを調整することで、**統計モデル**を構築します」(1-7節)

→ ちょっと抽象的でわかりにくい

→ まずは、具体例としての回帰分析を最初に説明する

背景：何で統計モデル？

なぜ統計モデルを使うのだろうか？

実は，旧課程の科目「統計学」では，統計モデルという用語はシラバスにはない．

- 大学の統計学では様々な手法（検定・回帰など）を，あまり関係づけずに個別に教えることも多かった
- しかし，統計モデルを用いると，様々な手法を統一的に扱うことができる
 - 考えが整理できる，理解も深まる
 - 特に，機械学習が普及して，統一的に考えるニーズが増えた
- Pythonのライブラリは，統計モデルを前提とした整理がされている

2. 回帰分析とは

回帰分析とは？

下図に、年齢と年収の関係を示す

- 相関係数：2つの変数の間で相関の強さを-1～1の数値で表した
 - 年齢と年収には相関がある/ない を言える
- 回帰分析：2つの変数について、下図のようなデータに「近い」直線（回帰直線）を求め、データを予測する分析手法

 alt

回帰分析は予測する手法

なぜ，回帰分析は予測する手法と言えるのか？

- 回帰直線がわかれば，直線上にある点を求める式がわかる

→ データには存在しない値でも，式に当てはめれば予測できる！

年齢 X と年収 Y の例の場合，以下の式が回帰直線を表す（有効数字3桁）

$$Y = 63.5 + 9.91X$$

例えば，データになかった35歳の年収は，以下の式で約410万と予測できる

$$Y = 63.5 + 9.91 \times 35 = 410.35$$

回帰分析は最も基本的な予測手法

データサイエンスにおいて、予測を行うためには、データの関係性を表す「モデル」を作成し、そのモデルにデータをあてはめ、予測値を求める

回帰分析は、1次関数（直線の式）をモデルとする最も基本的な予測手法

- 回帰分析（線形回帰）の仕組みは非常に単純だが、よく理解することが、今後、機械学習などの手法を理解する上で非常に重要

回帰分析に関連する用語

分析の対象となる，2つの変数を，以下のように区別する

- 説明変数：原因側の変数（X軸にとる）
- 目的変数：結果側の変数（Y軸にとる）

→ 説明変数の値から，目的変数の値を予測するという関係

この用語はいろいろな呼び方があるが，データサイエンス演習にそろえておく

回帰分析に関連する用語

予測するための以下の式を，**線形回帰式**と呼ぶ

$$Y = a + bX$$

- a：**定数**と呼ぶ
- b：**回帰係数**と呼ぶ

線形回帰式が表す，グラフ上の直線を**回帰直線**と呼ぶ

回帰直線用語

年齢と年収の例の線形回帰式, $Y = 63.5 + 9.91X$ を例に, 定数と回帰係数が何を表しているかを示す

 alt

回帰分析の例

実際の調査データに基づく例を挙げる．

- 目的変数 (Y) : 年収額, 説明変数 (X) : 1週間あたりの労働時間
- 日本版General Social Surveys<JGSS-2002>データ．60歳未満有識者

男性 : (N=718) $Y = 470.7 + 1.3X$

女性 : (N=615) $Y = -22.0 + 6.9X$

男性は, 労働時間が1時間増加すると年収が1.3万増加

- 女性は, 労働時間が1時間増加すると年収が6.9万増加

→ 女性は, 時間給で働くパートタイム就業者が多く, 労働時間の長さが収入に直結

2. 回帰直線はどうやって決める？：最小二乗法

回帰直線はどうやって決める？：最小二乗法

直感的には、回帰直線は、与えられたデータの間をほどよく通る直線だが・・・
数学的にはどうやって、この直線を決めるのだろうか？

→ 様々な直線を試してみて、各データからの「距離」が最小になれば良い

→ 「距離」って何？？ → 実測値と予測値の差，を使う

 alt

回帰直線はどうやって決める？：最小二乗法

残差平方和（residual sum of squares: RSSと略す）が最小になる直線を求めればよい

→ この手法を **最小二乗法** と呼ぶ

- 二乗したものを最小にすることから、この名前がついている
 - 英語では, ordinary least squares (OLSと略す)

残差平方和は以下で表される（残差を e_i で表し, X_i に対する予測値を $\hat{Y}_i$ で表す）

$$RSS = \sum_{i=1}^N e_i^2 = \sum_{i=1}^N (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^N \{Y_i - (a + bX_i)\}^2$$

残差（residual）と偏差（deviation）は似ているが、違いを理解しておこう
（偏差は平均との差）

最小二乗法の数学的な解き方の概要

数学的な解き方の概要だけ説明する．これは，他の機械学習の手法で使う数学的な解き方の基本だからデータサイエンス希望者は理解しておくこと

やりたいこと： $S = \sum_{i=1}^N \{Y_i - (a + bX_i)\}^2$ を最小にする a と b を求めたい

まず，この式が意味するものを理解する． X_i と Y_i には，データの値（定数）が入る

→ S は，展開すれば a と b に関する二次式となる（ a, b を変数と見る！頭の切替要）

→ これは a, b, S の3次元空間の中の二次曲面．かつ常に0または正

→ S が最小となるのは， a と b に関する微分が0になる点！（微分積分の知識）

（下に凸になる曲面をイメージせよ）

最小二乗法の数学的な解き方の概要

すごく直感的に言えば下図のイメージ（3次元ではなく2次元で表現している）

- a についても b についてもこれが成り立つ（3次元空間を横からみたと思えばよい）

 alt

最小二乗法の数学的な解き方の概要

aとbに関する微分が0 → 偏微分が0 よって、合成関数の微分を用いれば

$$\frac{\partial S}{\partial a} = -2 \sum (Y_i - a - bX_i) = 0$$

$$\frac{\partial S}{\partial b} = -2 \sum (Y_i - a - bX_i)X_i = 0$$

これを整理すると以下の連立一次方程式が得られる．これを正規方程式と呼ぶ

$$\begin{aligned} na + (\sum X_i)b &= \sum Y_i \\ (\sum X_i)a + (\sum X_i^2)b &= \sum X_i Y_i \end{aligned}$$

最小二乗法の数学的な解き方の概要

正規方程式を解けば（少し複雑だが中学生の知識で解ける），
XとYの平均をそれぞれ $\bar{X}$, $\bar{Y}$ とすると，以下の結果が得られる．
これが回帰直線の傾き（回帰係数）と切片（定数）である

$$b = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2}$$
$$a = \bar{Y} - b\bar{X}$$

例題：年齢と年収

資料と同じ，年齢と年収に関するデータがノートブックに入っている．

- (1) 年齢を説明変数，年収を目的変数として，このデータから回帰係数と定数を求めよ．
- (2) (1)の結果からわかる回帰式を用いて，年齢35歳の年収，年齢65歳の年収を予測せよ
- (3) データと回帰直線をグラフで図示せよ

演習：販売金額と耕地面積

次のデータは，北海道のある地域から無作為に抽出した20戸の農家の農産物の2005年度の販売金額と総経営耕地面積のデータである．

- (1) 総経営耕地面積を説明変数，販売金額を目的変数として，回帰係数と定数の値を求めよ．
- (2) (1)の結果からわかる回帰式を用いて，耕地面積200に対する販売金額の予測値，耕地面積700に対する販売金額の予測値を求めよ
- (3) データと回帰直線をグラフで図示せよ

注意：変数を逆にしないように注意すること

3. 係数の検定

回帰係数の検定

回帰分析で使うデータを母集団から抽出された標本（サンプル）と考えて、標本から求めた回帰係数から、母集団の回帰係数について統計的検定を行える。

回帰係数の検定とは、母集団において、説明変数の値による目的変数の値の変化があるかどうか、を検定する

- つまり、回帰係数が0であるかを検定する
- 0であるかどうかだけしかわからない

 alt

回帰係数の検定：帰無仮説と対立仮説

母集団における回帰係数を β （ベータ）としよう

帰無仮説： $H_0 : \beta = 0$

対立仮説： $H_0 : \beta \neq 0$

となる．

回帰係数の検定：検定統計量

回帰係数の検定には，以下の検定統計量を用いる．これは自由度 $N-2$ の t 分布に従う

$$t_{(df=N-2)} = \frac{b}{\sqrt{\frac{RSS/(N-2)}{\sum (X_i - \bar{X})^2}}}$$

- b ：回帰係数（傾き）
- 分母は回帰係数の標準誤差（ばらつき）
 - RSS ：残差平方和（Residual Sum of Squares）
 - $\sum (X_i - \bar{X})^2$ ：説明変数の偏差平方和
- 残差平方和が小さければ，棄却に傾く

回帰係数の検定の適用例

前に例にあげた全国調査に基づく労働時間と年収額の回帰分析で、男女それぞれの回帰係数について検定を行うと、以下の結果が得られる（そうだ）

- 男性：回帰係数 1.342，標準誤差 0.814 → 検定統計量=1.647
- 女性：回帰係数 6.926，標準誤差 0.533 → 検定統計量=12.984

標本サイズは十分大きい（男性718，女性615）ので，t分布は正規分布で近似できると考え，95%の上側限界値である1.96と比較すると

- 男性→帰無仮説を受容
- 女性→帰無仮説を棄却→女性は労働時間は年収額に対して効果がある

例題・演習

→ statsmodelsを使うのが良いので、次回以降で扱う