

情報数学III

第11回 統計モデルとは？

鈴木源吾

前回の復習

1. 統計モデルと回帰分析
2. 回帰分析とは
3. 回帰直線はどうやって決める？：最小二乗法
4. 係数の検定

今回のトピック

1. 統計モデルとは？
2. statsmodelsを使った回帰分析と係数の検定
3. 最小二乗法と最尤推定法

教科書：第7部，第8部 第1章（すべて一部）

1. 統計モデルとは？

教科書の記述と若干異なるが、改めて丁寧に説明していく

モデルとは何か？

- 「モデル」とは，複雑な現実を単純な仕組みで近似するための枠組みである．
- 例えば，てんとう虫の体長は個体ごとに異なるが，全体として一定の傾向があると考えられる．
- このような傾向を数式で表現するのがモデルであり，**数理モデル**と呼ばれる．

統計モデルとは何か？

- 統計モデルとは、「**パラメータを含む確率分布**」でデータの生成過程を表現したものである。
- データがある確率的なルールに従って得られているという前提を置き、そのルールの構造（分布の形やパラメータ）をモデル化する。
- 統計モデルを立てることで、**推定・検定・予測**が可能になる。

モデルの例：てんとう虫の体長

- 個体ごとに体長は異なるが、正規分布に従うと仮定しよう.
- 平均 μ ，分散 σ^2 の正規分布とすれば，以下のように記述する：

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

- μ ， σ^2 は未知のパラメータであり，データから推定する対象である.

点推定とは

- **点推定**とは，統計モデルのパラメータを，データから1つの値として推定することである．
- 例：標本平均 $\bar{x}$ により母平均 μ を推定

例：てんとう虫の体長データから

平均体長 $\bar{x} = 0.8 \text{ mm}$

→ 「 $\mu \approx 0.8$ 」と推定

統計モデルが必要な理由

- データだけでは，平均や関係性の根拠が明確でない．
- 統計モデルを仮定することで：
 - どのような量（パラメータ）を推定すべきかが明確になる．
 - 推定値のばらつきや検定の正当性が，確率論に基づいて扱えるようになる．

回帰モデルとは何か

- 回帰分析では，変数 x （説明変数）と y （目的変数）の関係を数式で表した．
- 誤差も含む形で表現しよう．次が，一次回帰モデルの基本形：

$$y = a + bx + \varepsilon$$

- ここで a は切片， b は傾き， ε は誤差項（ずれ）である．
- 実データは直線にぴったり乗らないため，この誤差を含めてモデル化する．

回帰モデルは統計モデルの一種

- 回帰モデルは、**パラメータを含む確率分布**として理解される。
- 誤差項 ε を確率変数（通常は $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ ）と仮定することで、モデル全体が確率モデルとなる。
- よって、回帰モデルは以下のような**統計モデル**になる：

$$Y = a + bX + \varepsilon \quad \Rightarrow \quad Y \sim \mathcal{N}(a + bX, \sigma^2)$$

- X, Y は確率変数， a, b, σ^2 はパラメータである。

例：年齢と年収の回帰モデル

- 目的変数：年収（万円），説明変数：年齢（歳）
- モデル式：

$$\text{年収} = a + b \times \text{年齢} + \varepsilon$$

- 誤差 ε を導入することで，
「年齢が同じでも年収がばらつく」現象を表現できる．

推定とパラメータ

- このモデルのパラメータは、 a （切片）、 b （傾き）、 σ^2 （誤差の分散）である。
- 実データから、これらを推定するのが**回帰分析の目的**である。
- 推定法として、前回学んだ**最小二乗法**を用いる。

回帰モデルのまとめ

- 回帰モデルは、**確率的な数理モデル＝統計モデル**である．
- パラメータ a , b は点推定や検定の対象となる．
- 誤差項の仮定により，回帰分析は統計的推論の枠組みに位置づけられる．

誤差の分散 σ^2 の推定

- 回帰式 $y = a + bx$ は、「平均的な関係」を表すだけである．
- 実際のデータは，この直線からズレる（＝**残差**）：

$$e_i = y_i - (a + bx_i)$$

- この残差のばらつきから，**誤差の分散 σ^2** を推定する（教科書 p.401）：

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - a - bx_i)^2$$

- σ^2 が推定できることで，モデル全体が**確率的な統計モデル**として完成する．

なぜ分母が $n - 2$ なのか？

- 残差の分散 σ^2 を推定する式は：

$$\hat{\sigma}^2 = \frac{1}{n - 2} \sum_{i=1}^n (y_i - a - bx_i)^2$$

- 最小二乗法で、 a と b の2つのパラメータを推定している。
- 2つの制約がデータにかかっているため、**残差の自由度が2つ減る**：

$$\text{自由度} = n - 2$$

- 分散推定では、常に「使用したパラメータの分だけ自由度が減る」ことに注意。

Topic 2

statsmodelsを使った回帰分析と係数の検定

- Pythonライブラリ `statsmodels` を用いると，回帰モデルの推定や係数の検定が簡単に行える．
- ノートブック上で結果を確認しながら，統計的な意味を理解することが目的である．

例題：年齢と年収

前回と同じ例題をstatsmodelsを使って実施する．

- (1) 年齢を説明変数，年収を目的変数として，このデータから回帰係数と定数を求めよ．
- (2) (1)の結果からわかる回帰式を用いて，年齢35歳の年収，年齢65歳の年収を予測せよ
- (3) データと回帰直線をグラフで図示せよ

回帰分析の出力（例題）

	coef	std err	t	P> t	[0.025	0.975]
Intercept	63.4946	162.380	0.391	0.706	-310.954	437.943
age	9.9104	4.019	2.466	0.039	0.643	19.178

- coef：推定されたパラメータ（点推定値）
- std err：標準誤差（推定値のばらつき）
- t：検定統計量（t値）
- P>|t|：p値（帰無仮説のもとでの確率）
- [0.025 0.975]：95%信頼区間（パラメータの範囲の推定）

その他の指標（決定係数など）は次回以降に説明する．

検定の枠組み（係数が 0 かどうか）

- 各係数に対して、以下の仮説を検定している：

$$H_0 : \text{係数} = 0 \quad \text{vs} \quad H_1 : \text{係数} \neq 0$$

- t 値が大きい $\rightarrow$ 有意に 0 でない可能性あり
- p 値が小さい $\rightarrow$ 帰無仮説を棄却できる（例： $p < 0.05$ ）
- 信頼区間に 0 を含まない $\rightarrow$ 係数が有意である

Topic 3

最小二乗法と最尤推定法

最小二乗法と最尤推定法

- 回帰分析では、最小二乗法により係数 a, b を求めてきた。
- これは、「誤差の二乗和が最小になるように」係数を決める方法である。
- 一方、統計モデルでは、「このパラメータならデータが出てきそう」という確率を最大にするという考え方がある。
- それが**最尤推定法**（MLE, Maximum Likelihood Estimation）である。

最尤推定法（MLE）とは

- 最尤推定法とは、「実際に得られたデータがもっともらしく見えるように、パラメータを決める方法」である。
- 尤もらしさを定量化するために、**尤度関数**（likelihood function）を用いる。

尤度関数の定義

- 統計モデル： $X_1, \dots, X_n \sim f(x; \theta)$
(θ は未知のパラメータ)
- 実際に得られたデータ： $x_1, x_2, \dots, x_n$
- このときの**尤度関数**は：

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta)$$

- この $L(\theta)$ を最大にする θ を探するのが最尤推定法である．

例：正規分布の平均の最尤推定

- モデル： $X_i \sim \mathcal{N}(\mu, \sigma^2)$ (σ は既知とする)
- 尤度関数（定数項を除く）：

$$L(\mu) \propto \exp \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right)$$

- 対数尤度をとって最大化する：
 - 「**データとの二乗誤差が最も小さくなるような μ を求めよ**」 という意味

$$\hat{\mu} = \arg \min_{\mu} \sum_{i=1}^n (x_i - \mu)^2$$

- → **最小二乗法と一致**

回帰モデルでの最尤推定

- 回帰モデル： $Y_i = a + bX_i + \varepsilon_i$, $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$
- このとき, Y_i の分布は： $Y_i \sim \mathcal{N}(a + bX_i, \sigma^2)$
- 尤度関数は：

$$L(a, b) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - a - bx_i)^2}{2\sigma^2}\right)$$

- 対数尤度の最大化 $\Leftrightarrow$ 残差平方和の最小化：

$$\hat{a}, \hat{b} = \arg \min_{a, b} \sum_{i=1}^n (y_i - a - bx_i)^2$$

- よって, **最小二乗法と最尤推定法は一致する.**

最小二乗法と最尤推定のまとめ

- **最小二乗法**：誤差の二乗和を最小にする．
- **最尤推定法**：データが得られる確率（尤度）を最大にする．
- 正規分布を仮定すれば，両者は同じ推定結果を与える．
- 統計モデルの考え方では，**最尤推定の枠組みがより一般的**である．