

情報数学III

第11回 統計モデルとは？

鈴木源吾

前回の復習

1. 統計モデルと回帰分析
2. 回帰分析とは
3. 回帰直線はどうやって決める？：最小二乗法
4. 係数の検定

今回のトピック

1. 統計モデルとは？
2. statsmodelsを使った回帰分析と係数の検定
3. 最小二乗法と最尤推定法

教科書：第7部，第8部 第1章（すべて一部）

1. 統計モデルとは？

教科書の記述と若干異なるが、改めて丁寧に説明していく

モデルとは何か？

- 「モデル」とは，複雑な現実を単純な仕組みで近似するための枠組みである．
- 例えば，てんとう虫の体長は個体ごとに異なるが，全体として一定の傾向があると考えられる．
- このような傾向を数式で表現するのがモデルであり，**数理モデル**と呼ばれる．

統計モデルとは何か？

- 統計モデルとは、「**パラメータを含む確率分布**」でデータの生成過程を表現したものである。
- データがある確率的なルールに従って得られているという前提を置き、そのルールの構造（分布の形やパラメータ）をモデル化する。
- 統計モデルを立てることで、**推定・検定・予測**が可能になる。

モデルの例：てんとう虫の体長

- 個体ごとに体長は異なるが、正規分布に従うと仮定しよう.
- 平均 μ ，分散 σ^2 の正規分布とすれば，以下のように記述する：

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

- μ ， σ^2 は未知のパラメータであり，データから推定する対象である.

統計モデルを式で表す

- 統計モデルは「**パラメータ θ を含む確率分布**」だった．その**確率密度関数**を $f(x; \theta)$ と書く（離散なら確率 $P(X = x; \theta)$ ）．

- 例：てんとう虫 $X \sim \mathcal{N}(\mu, \sigma^2)$ では $\theta = (\mu, \sigma^2)$,

$$f(x; \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

- 観測データ $x_1, \dots, x_n$ は，**同じ分布から互いに独立に**得られたと仮定する (i.i.d.) .
 - i.i.d. = independent and identically distributed (**独立同分布**) の略．
 - 「**独立**」＝各データが互いに影響しない，「**同分布**」＝全員が同じ $f(x; \theta)$ から得られる，という意味．

点推定とは

- **点推定**とは，統計モデルのパラメータを，データから1つの値として推定することである．
- 例：標本平均 $\bar{x}$ により母平均 μ を推定

例：てんとう虫の体長データから

平均体長 $\bar{x} = 0.8 \text{ mm}$

→ 「 $\mu \approx 0.8$ 」と推定

統計モデルが必要な理由

- データだけでは、平均や関係性の根拠が明確でない。
- 統計モデルを仮定することで：
 - どのような量（パラメータ）を推定すべきかが明確になる。
 - 推定値のばらつきや検定の正当性が、確率論に基づいて扱えるようになる。

回帰モデルとは何か

- 回帰分析では，変数 X （説明変数）と Y （目的変数）の関係を数式で表した．
- 誤差も含む形で表現しよう．次が，一次回帰モデルの基本形：

$$Y = a + bX + \varepsilon$$

- ここで a は切片， b は傾き， ε は誤差項（ずれ）である．
- 実データは直線にぴったり乗らないため，この誤差を含めてモデル化する．

回帰モデルは統計モデルの一種

- 回帰モデルは、**パラメータを含む確率分布**として理解される。
- 誤差項 ε を確率変数（通常は $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ ）と仮定することで、モデル全体が確率モデルとなる。
- よって、回帰モデルは以下のような**統計モデル**になる：

$$Y = a + bX + \varepsilon \quad \Rightarrow \quad Y \sim \mathcal{N}(a + bX, \sigma^2)$$

- X, Y は確率変数， a, b, σ^2 はパラメータである。
- ※ 1個のデータの関係は $Y = a + bX + \varepsilon$ ． n 個のデータを区別するときは添え字をつけ， $Y_i = a + bX_i + \varepsilon_i$ ($i = 1, \dots, n$) と書く。

例：年齢と年収の回帰モデル

- 目的変数：年収（万円），説明変数：年齢（歳）
- モデル式：

$$\text{年収} = a + b \times \text{年齢} + \varepsilon$$

- 誤差 ε を導入することで，
「年齢が同じでも年収がばらつく」現象を表現できる．

推定とパラメータ

- このモデルのパラメータは、 a （切片）、 b （傾き）、 σ^2 （誤差の分散）である。
- 実データから、これらを推定するのが**回帰分析の目的**である。
- 推定法として、前回学んだ**最小二乗法**を用いる。

回帰モデルのまとめ

- 回帰モデルは、**確率的な数理モデル＝統計モデル**である．
- パラメータ a , b は点推定や検定の対象となる．
- 誤差項の仮定により、回帰分析は統計的推論の枠組みに位置づけられる．

誤差の分散 σ^2 の推定

- 回帰式 $Y = a + bX$ は、誤差 ε を除いた「平均的な関係」を表すだけである。
- 実際のデータは、この直線からズレる（=**残差**）：

$$e_i = y_i - (a + bx_i)$$

- 残差平方和を $RSS = \sum_{i=1}^n (y_i - a - bx_i)^2$ とおくと、この残差のばらつきから **誤差の分散 σ^2** を推定できる（教科書 p.401）：

$$\hat{\sigma}^2 = \frac{RSS}{n-2} = \frac{1}{n-2} \sum_{i=1}^n (y_i - a - bx_i)^2$$

- σ^2 が推定できることで、モデル全体が**確率的な統計モデル**として完成する。

なぜ分母が $n - 2$ なのか？

- 誤差の分散 σ^2 の推定式は：

$$\hat{\sigma}^2 = \frac{RSS}{n - 2}$$

- 最小二乗法で、 a と b の2つのパラメータを推定している．
- 2つの制約がデータにかかっているため、**残差の自由度が2つ減る**：

$$\text{自由度} = n - 2$$

- 分散推定では、常に「使用したパラメータの分だけ自由度が減る」ことに注意．

誤差の分散はどこで使う？（第10回とのつながり）

- 第10回の回帰係数の検定で出てきた**標準誤差**は、この $\hat{\sigma}^2$ から作られる：

$$SE(b) = \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}, \quad \hat{\sigma}^2 = \frac{RSS}{n - 2}$$

- 検定統計量 $t = \frac{b}{SE(b)}$ は、この $\hat{\sigma}^2$ （誤差の分散）を使っていた。
- 注意：** $\hat{\sigma} = \sqrt{\hat{\sigma}^2}$ （＝回帰の標準誤差，点の散らばり）と，**係数の標準誤差 $SE(b)$ は別物**． $SE(b)$ は $\hat{\sigma}$ を x の散らばり $\sqrt{\sum (x_i - \bar{x})^2}$ でさらに割る．
- （第10回では N と表記したが、同じデータ数を表す n ．）

Topic 2

statsmodelsを使った回帰分析と係数の検定

- Pythonライブラリ `statsmodels` を用いると，回帰モデルの推定や係数の検定が簡単に行える．
- ノートブック上で結果を確認しながら，統計的な意味を理解することが目的である．

例題：年齢と年収

前回と同じ例題をstatsmodelsを使って実施する．

- (1) 年齢を説明変数，年収を目的変数として，このデータから回帰係数と定数を求めよ．
- (2) (1)の結果からわかる回帰式を用いて，年齢35歳の年収，年齢65歳の年収を予測せよ
- (3) データと回帰直線をグラフで図示せよ

回帰分析の出力（例題）

	coef	std err	t	P> t	[0.025	0.975]
Intercept	63.4946	162.380	0.391	0.706	-310.954	437.943
age	9.9104	4.019	2.466	0.039	0.643	19.178

- coef：推定されたパラメータ（点推定値）
- std err：標準誤差（推定値のばらつき）
- t：検定統計量（t値）
- P>|t|：p値（帰無仮説「係数=0」が正しいとき，観測された t 以上に極端な値が出る確率）
- [0.025 0.975]：95%信頼区間（パラメータの範囲の推定）

その他の指標（決定係数など）は次回以降に説明する．

検定の枠組み（係数が0かどうか）

- 各係数に対して、以下の仮説を検定している：

$$H_0 : \text{係数} = 0 \quad \text{vs} \quad H_1 : \text{係数} \neq 0$$

- **検定での読み方**： t 値が大きい／ p 値が小さい（例： $p < 0.05$ ）→ 帰無仮説を棄却 → 係数は有意
- **信頼区間での読み方（区間推定）**：95%信頼区間が0を含まない → 「0ではない」と判断できる
- → 検定と区間推定は**表裏の関係**で、同じ結論になる

Topic 3

最小二乗法と最尤推定法

最小二乗法と最尤推定法

- 回帰分析では、最小二乗法により係数 a, b を求めてきた。
- これは、「誤差の二乗和が最小になるように」係数を決める方法である。
- 一方、統計モデルでは、「このパラメータならデータが出てきそう」という確率を最大にするという考え方がある。
- それが**最尤推定法**（MLE, Maximum Likelihood Estimation）である。

最尤推定法（MLE）とは

- 最尤推定法とは、「観測したデータが得られる確率（＝尤度）が最大になるように、パラメータを決める方法」である。
- 「そのパラメータのもとで、実際のデータがどれくらい得られやすいか」を表すのが**尤度**であり、これを関数の形にしたものが**尤度関数**（likelihood function）である。

尤度関数の定義

- データ $x_1, \dots, x_n$ は、独立に同じ分布 $f(x; \theta)$ から得られた（前ページ）。
- 独立なので、これらが**同時に**得られる確率は各確率の**積**になる：

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta)$$

- これをパラメータ θ の関数とみたものが**尤度関数**である。
- この $L(\theta)$ を最大にする θ を探すのが最尤推定法である。

例：正規分布の平均の最尤推定

- モデル： $X_i \sim \mathcal{N}(\mu, \sigma^2)$ (σ は既知とする).
- 密度 $f(x; \mu)$ を尤度 $\prod_{i=1}^n f(x_i; \mu)$ に代入すると ($\propto$ は比例： μ によらない定数倍を除く)：

$$L(\mu) \propto \exp \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right)$$

- 対数尤度をとって最大化する：
 - 「**データとの二乗誤差が最も小さくなるような μ を求めよ**」 という意味

$$\hat{\mu} = \arg \min_{\mu} \sum_{i=1}^n (x_i - \mu)^2$$

- → **最小二乗法と一致**

回帰モデルでの最尤推定

- 回帰モデル： $Y_i = a + bX_i + \varepsilon_i$, $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$
- このとき, Y_i の分布は： $Y_i \sim \mathcal{N}(a + bX_i, \sigma^2)$
- 尤度関数は：

$$L(a, b) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(y_i - a - bx_i)^2}{2\sigma^2} \right)$$

- 対数尤度の最大化 $\Leftrightarrow$ 残差平方和の最小化：

$$\hat{a}, \hat{b} = \arg \min_{a, b} \sum_{i=1}^n (y_i - a - bx_i)^2$$

- よって, **最小二乗法と最尤推定法は一致する.**

最小二乗法と最尤推定のまとめ

- **最小二乗法**：誤差の二乗和を最小にする．
- **最尤推定法**：データが得られる確率（尤度）を最大にする．
- 正規分布を仮定すれば，両者は同じ推定結果を与える．
- 統計モデルの考え方では，**最尤推定の枠組みがより一般的**である．