

情報数学III

第12回 決定係数と分散分析

鈴木源吾

前回の復習

1. 統計モデルとは？
2. statsmodelsを使った回帰分析と係数の検定
3. 最小二乗法と最尤推定法

今回のトピック

1. 決定係数
 - 予測の精度と決定係数
2. 分散分析


教科書：第8部 第2・3章

1. 決定係数

回帰分析による予測の精度

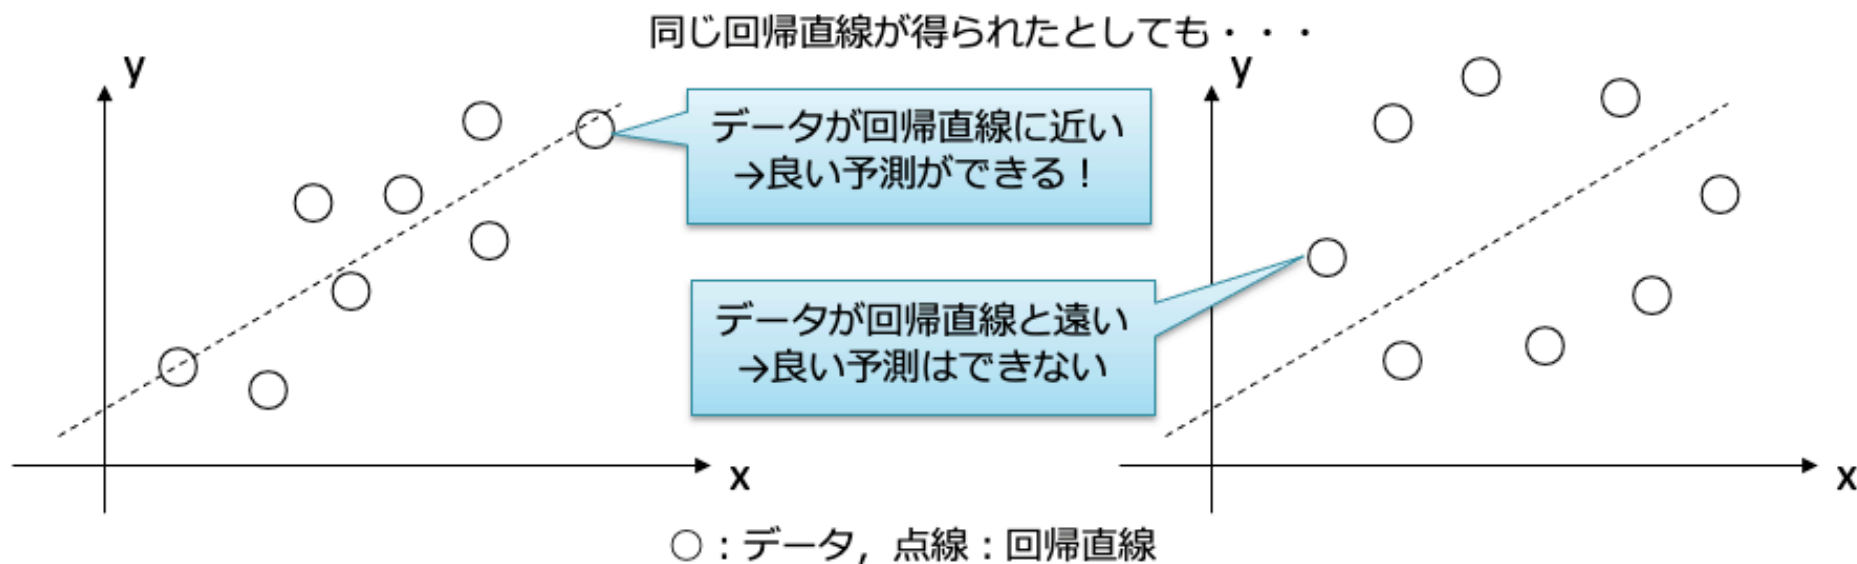
回帰分析 → 「予測」の手法 だった

- 予測の誤差（残差）が最小になるように回帰式を決めた（下図）
- しかし，回帰分析による予測の「よさ」（精度）はデータに依存する（次頁）



データによる回帰分析の精度の良し悪し

- 同じ回帰直線が得られたとしても
 - 左図のように、データが回帰直線に近ければ、この直線はデータの分布に近いから良い予測ができると考えられる
 - 一方、右図のように、データが回帰直線から遠ければ、この直線を使って予測をしても良い結果は得られないだろう




予測精度を表す指標

よって、回帰直線によりどの程度の精度で予測できるかの指標がほしい
＝モデルの評価指標の一つ

この場合、「予測の誤差＝残差がどの程度まで減少したか」で測れば良い


どの程度まで??? → どこから???

→ これは平均による予測を最悪ケースと考え、それとの差で考えれば良い





予測精度を表す指標



yの平均を
予測値した
予測が最悪
な予測



残差が大き
く減る→良
いモデル



残差が減ら
ない→悪い
モデル




最悪ケースの残差は？：全平方和

最悪ケースの残差は「目的変数の平均 ($\bar{Y}$) との差の二乗の総和」だから・・・

$$TSS = \sum (Y_i - \bar{Y})^2$$


→ **全平方和**と呼ぶ (TSS は、Total Sum of Squaresの略)



回帰直線の予測誤差は？：残差平方和

回帰直線による予測誤差は，以前学んだ残差平方和になる

$$RSS = \sum (Y_i - \hat{Y}_i)^2 \quad (\hat{Y}_i \text{は予測値})$$




どれだけよくなった？：回帰平方和

となると，回帰分析によって， $TSS - RSS$ の量の残差が減少したことになる．

→ 回帰平方和と呼ぶ（Explained Sum of Squares. ESSと約す）

以下の式で表される（ $TSS = RSS + ESS$ は証明できる（省略））

$$ESS = \sum (\hat{Y}_i - \bar{Y})^2$$



決定係数

Y の変動のうち回帰直線で説明できる部分の割合を，決定係数と呼び，以下で定義する（coefficient of determination. R^2 で表記）

$$R^2 = \frac{ESS}{TSS} = \frac{TSS - RSS}{TSS} = 1 - \frac{RSS}{TSS}$$

- 0から1までの値をとる
 - 回帰直線が目的変数の平均値に等しい場合，決定係数は0となる（最悪ケース）
 - すべてのデータが回帰直線上にある場合，残差は0になるから，決定係数は1になる（最良ケース）
- 決定係数は，目的変数の予測値と実測値との相関係数（重相関係数と呼ばれる）の二乗に相当する．わざわざ二乗の表記で表されている理由

例題1：決定係数を求めてみよう

年齢と年収額の例（以前のデータと異なるので注意）がある．このデータに基づいて回帰分析を行い，決定係数を求めてみよう．

- 決定係数は，0.473（47.3%）となる
- 年収額の散らばりの約半分は年齢によって説明され，残りの半分はそれによって説明できない誤差であると評価できる

2. 分散分析


2群の平均の差の検定の振り返り

例：施肥（肥料をやること）の有無がある穀物の収量に影響を及ぼすかどうかの実験

まずは、2群で実験することを考えてみよう

肥料なし

収量



肥料あり（大）

収量



肥料の効果
ある？



2群の平均の差の検定を用いて、肥料の
効果があるかどうかを判断した

平均の2と12を比較→差があるか？

- t分布を使って判断（小標本）


収量の単位はt/ha

（1ヘクタールあたり何トン収穫できたか）

多群の関係を調べたい

しかし，肥料の効果をみたいのなら，通常，肥料の量を変化させてどのように効果が変化をするのかを調べたい

→ 多群の比較をしたい




これらの群を「水準」と呼ぶ
この例は3つの水準を持つ

分散分析の概要

分散分析：研究目的となる**要因**（因子）の効果の有無を実験結果から判定する手法

- 前ページの例の場合，要因は施肥量 → 施肥量の効果はあるのか？
- 一つ一つの差ではなく，全体としての効果を見るのが分散分析


→ では，要因の効果とは何を測ればわかるのだろうか？



回帰分析との共通点


分散分析はやや分かりづらいが，施肥量と収量の関係であれば，以下のようなグラフをイメージすればよい．回帰分析の検定にも近い（教科書 p.431の例も同様）

注意：一般的には，分散分析における水準には，複数の要因を用いてもかまわない（例：2種類の肥料の量）



要因の効果・変動とは？


「データ全体の変動」＝「要因による変動」＋「誤差による変動」
→ 要因の比率が高い → 要因の効果が大きい



全体の変動（総変動）

具体例で変動を見てみよう（決定係数での、 $TSS = RSS + ESS$ をイメージするとよい）

全体の変動（総変動）は、全体の平均（総平均）と各値との差の平方和（TSS相当）




要因による変動（群間変動）

誤差による影響がなければ同じ群（水準）内の値は同じになるはず

→ **群内平均と総平均の差**が群間の差異

→ その平方和が群間変動（ESS相当）




$$\begin{aligned} \text{群間変動} &= \sum \sum (\text{群平均} - \text{総平均})^2 \\ &= 25 + 25 + 0 + 0 + 25 + 25 \\ &= \underline{100} \end{aligned}$$

誤差による変動（群内変動）

本来同じ値となるはずの群（水準）内の値がばらつくのは誤差による効果

→ 各値と各群の平均との差が誤差

→ その平方和が群内変動



全体変動=群間変動+群内変動

いままでの3つの結果をあわせると，確かに変動の和の式が成立
(TSSの分解と同等の式)


総変動		群間変動		群内変動
$= \sum \sum (\text{値} - \text{総平均})^2$		$= \sum \sum (\text{群平均} - \text{総平均})^2$	+	$= \sum \sum (\text{値} - \text{群平均})^2$
$= 36 + 24 + 1 + 1 + 9 + 94$	=	$= 25 + 25 + 0 + 0 + 25 + 25$		$= 1 + 1 + 1 + 1 + 4 + 4$
$= \underline{112}$		$= \underline{100}$		$= \underline{12}$

分散分析における仮説検定（F検定）

要因による効果があったのかを検定したい

- 検定統計量は，群間変動（要因効果）と群内変動（誤差効果）の比率としたいが・・・このままでは適切な確率分布に従わない
- 2つの変動を，それぞれの自由度で割って不偏分散にする
 - その比率はF分布に従う
 - F検定が使える！（等分散の検定と同様）

効果の有無の判定方法



群間の不偏分散

$$\begin{aligned}\text{総変動} &= \sum \sum (\text{値} - \text{総平均})^2 \\ &= 36 + 24 + 1 + 1 + 9 + 94 \\ &= \underline{112}\end{aligned}$$

=

$$\begin{aligned}\text{群間変動} &= \sum \sum (\text{群平均} - \text{総平均})^2 \\ &= 25 + 25 + 0 + 0 + 25 + 25 \\ &= \underline{100}\end{aligned}$$

+

$$\begin{aligned}\text{群内変動} &= \sum \sum (\text{値} - \text{群平均})^2 \\ &= 1 + 1 + 1 + 1 + 4 + 4 \\ &= \underline{12}\end{aligned}$$



$$\begin{aligned}\text{自由度} &= \text{水準数} - 1 \\ &= 3 - 1 = 2\end{aligned}$$



$$\begin{aligned}\text{自由度} &= \text{データ総数} - \text{水準数} \\ &= 6 - 3 = 3\end{aligned}$$

- 群間変動の大きさ（不偏分散の分子） $= \sum \sum (\text{群平均} - \text{総平均})^2 = 100$
- 群間変動の自由度（不偏分散の分母） $= \text{水準数} (3) - 1 = 2$
- 群間の分散（不偏分散） $= \text{群間変動} (100) / \text{自由度} (2) = \mathbf{50}$

群内の不偏分散

$$\begin{aligned}\text{総変動} &= \sum \sum (\text{値} - \text{総平均})^2 \\ &= 36 + 24 + 1 + 1 + 9 + 94 \\ &= \underline{\underline{112}}\end{aligned}$$

=

$$\begin{aligned}\text{群間変動} &= \sum \sum (\text{群平均} - \text{総平均})^2 \\ &= 25 + 25 + 0 + 0 + 25 + 25 \\ &= \underline{\underline{100}}\end{aligned}$$

+

$$\begin{aligned}\text{群内変動} &= \sum \sum (\text{値} - \text{群平均})^2 \\ &= 1 + 1 + 1 + 1 + 4 + 4 \\ &= \underline{\underline{12}}\end{aligned}$$




$$\begin{aligned}\text{自由度} &= \text{水準数} - 1 \\ &= 3 - 1 = 2\end{aligned}$$



$$\begin{aligned}\text{自由度} &= \text{データ総数} - \text{水準数} \\ &= 6 - 3 = 3\end{aligned}$$

- 群内変動の大きさ（不偏分散の分子） $= \sum \sum (\text{各値} - \text{群内平均})^2 = 12$
- 群内変動の自由度（不偏分散の分母） $= \text{データ総数} (6) - \text{水準数} (3) = 3$
- 群内の分散（不偏分散） $= \text{群内変動} (12) / \text{自由度} (3) = \mathbf{4}$

分散分析による仮説検定（施肥量の例）



帰無仮説を棄却

(要因効果あり→「施肥によって収量は増えた」)

分散分析の計算の理解

ノートブックを参照

分散分析における対応のある/なし

今まで述べた分散分析は、「対応のない」場合の分散分析だった

- 施肥量の例で言えば，異なる区画で同時に実験した場合

「対応のある」場合の分散分析も考えることができる

- 施肥量の例で言えば，同じ区画で施肥量を変えて実験した場合

ある/なしの考え方は，2群の平均の差の検定の場合と同じ

例：喫煙本数

→複数回のカウンセリングを受けた後で，喫煙本数は変化するか？

(平均の差における，補習を受けたらテストの点が変わるか？の例と同様)

教科書に記述ないので，詳細は省略

要因が2つ以上ある場合の分散分析

- 前の例は，要因が1つ（施肥量）の分散分析だった
- 要因が2つ以上ある場合でも分散分析は可能
- 要因が2つ→二元配置分散分析
- 要因が1つ→一元配置分散分析
- 要因が3つ以上→多元配置分散分析

二元配置分散分析に使うデータ


二元配置分散分析の例をあげる．2つの要因がある．

- 堆肥（単位：mg/ポット）とAM菌の接種がセイヨウミヤコグサの生育に与える影響
- 数値は乾物量（水分を除いた植物の重量．単位g/ポット）

	水準1(0)	水準2(10)	水準3(30)	水準4(50)
AM菌接種	16.3	39.6	47.7	48.5
	18.9	41.6	48	51.7
	18.8	39.2	51	46.5
	16.4	40.4	43.7	43.8
AM菌非接種	13.6	38.3	41.9	44.1
	8.8	37.5	45.4	45.9
	17.9	36.3	45.3	44.4
	10.8	39	43.7	40.7

二元配置分散分析

- 詳細は省略するが，基本的な考え方は一元配置と同じ → 計算例はノートブック
- 変動の一部として，**交互作用**を検討する必要がある
 - 交互作用：複数の要因で，ある特定の値が組み合わさったときにだけ現れる相乗（相殺）効果 → 教科書の第4章に記載あり．次回に解説予定



演習1（一元配置分散分析）

次のデータは，ある年の営農類型別農業所得（万円/経営体，仮想データ）である．水田作・果樹作・施設野菜作それぞれで経営体2件の農業所得を整理した．

水田	果樹	施設野菜
80	200	600
40	300	400

このデータから，営農類型によって農業所得が異なるといえるかを分散分析で検証せよ（有意水準 $\alpha = 5\%$ ）．結論まで文章で述べること．

演習2（二元配置分散分析）

次のデータは，人種と血圧の関係を見るための実験結果（仮想データ）である．アジア人・黒人・白人を各12名，うち半数（6名）には塩分控えめの食事を，残り半数には塩をふんだんに使った食事を1週間とってもらった（収縮期血圧，mmHg）．

データはノートブックに用意してある．このデータから，血圧に対する「**人種**」「**塩負荷**」および両者の**交互作用**の効果を二元配置分散分析で検定せよ（有意水準 $\alpha = 5\%$ ）．それぞれ有意だったか，結論まで述べること．