

情報数学III

第13回 正規線形モデル：複数の説明変数を持つモデル

鈴木源吾

前回の復習

1. 決定係数
 - 予測の精度と決定係数
2. 分散分析

今回のトピック

1. 重回帰分析

- 重回帰分析とは？
- 重回帰分析の結果を読む
- 自由度調整済み決定係数

2. 分散分析と回帰分析


3. 複数の説明変数を持つモデル

教科書：第8部 第4章

1. 重回帰分析

重回帰分析の必要性

- 第12回に学んだ回帰分析は、1つの目的変数に対して、1つの説明変数を用いて、予測を行おうとした
- しかし、ある事象に影響するような要因は複数もある → 複数の説明変数
- それぞれの説明変数をひとつずつ取り上げ、個別に回帰分析を行うこともできる
- しかし、様々な要因の効果を分析する上では適当ではない



重回帰分析

- そこで，想定される複数の要因を，同時に説明変数とした回帰式を立てて，係数の推定を行う

$$\hat{Y}_i = a + b_1 X_{1i} + b_2 X_{2i} + \cdots + b_k X_{ki}$$

- k個の複数の説明変数それぞれについて，回帰係数が推定されている
→ これらを**偏回帰係数**(partial regression coefficient)と呼ぶ
- このような複数の説明変数の線形結合から目的変数を予測する回帰分析を**重回帰分析**(multiple regression analysis)と呼ぶ
 - 説明変数がひとつの場合の回帰分析を，これと区別して単回帰分析と呼ぶこともある

重回帰分析における係数・定数の決定


- 偏回帰係数・定数の決定は、単回帰分析と同様に最小二乗法によって行う
- 基本的な考え方は同じだが、行列計算が必要になってくる
- 説明は省略する

例題1：重回帰分析

- 地価（土地の価格）が周辺環境からどのような影響を受けているのかを調べてみよう
- ノートブックにそのデータが入っている
- 例えば、番号1の地点の地価は、319千円/ m^2 で、その周辺25万 m^2 （500m四方）には、農地が200 m^2 ，林地が400 m^2 ，商業地が16000 m^2 ，密集住宅が7200 m^2 存在していることを示す
- ざっと見た感じでは、ちょっと傾向はわからないが・・・
- ノートブックに計算方法を示す。

重回帰分析の結果を読む：偏回帰係数と定数

- サマリーの真ん中の表の「coef（係数）」の欄に、偏回帰係数と定数の情報がある
- 切片→定数，その他が各説明変数に対する偏回帰係数となる
- 農地面積については，偏回帰係数が-0.771なので，周辺に農地が $100m^2$ 増えると， $1m^2$ あたりの地価が771円下がることを意味する（他の説明変数は一定で）
 - **農地面積が最も目的変数に影響を与える**（回帰係数の絶対値が最大）
- また，林地面積については，地価を上昇させる力があることがわかる

	係数	回帰式
切片	358.107	$Y = 358.107 - 0.771X_1 + 0.172X_2 - 0.110X_3 - 0.194X_4$ 
農地面積	-0.771	
林地面積	0.172	
商業地面積	-0.110	
密集住宅面積	-0.194	

標準偏回帰係数

- このように，すべての説明変数の単位が同一（面積で $100m^2$ ）であれば，偏回帰係数の絶対値を比較して，最も目的変数に影響を与える説明変数を求めることが可能である
- しかし，説明変数の単位が異なる場合は，そのままでは比較することはできない
- その場合は，目的変数を含めたすべての変数を標準化（平均を0，標準偏差を1とする）して，重回帰分析すれば，係数の大きさ＝影響力の強さとして比較できる
- 標準化してから求めた偏回帰係数を，標準偏回帰係数（標準化回帰係数）と呼ぶ
- 標準化して分析する例は，後の演習1でとりあげる
- 実際の単位で解釈したいときは，標準化しない方がよい
- 2値のカテゴリ変数（0, 1）は，標準化は不要（多値の場合はダミー変数化する）

重回帰分析の結果を読む：決定係数

前回に学んだ決定係数は、サマリーの上の表にある

- 「R-squared」が決定係数である
- 「Adj. R-squared」は自由度調整済み決定係数と呼ばれるもの（次頁説明）

OLS Regression Results

```
=====
Dep. Variable:          地価      R-squared:          0.711
Model:                  OLS      Adj. R-squared:       0.664
Method:                 Least Squares      F-statistic:      15.35
Date:                  Tue, 08 Jul 2025      Prob (F-statistic):  1.83e-06
Time:                  02:55:40      Log-Likelihood:     -139.46
No. Observations:      30      AIC:                288.9
Df Residuals:          25      BIC:                295.9
Df Model:              4
Covariance Type:       nonrobust
```

自由度調整済み決定係数が必要な理由

- 決定係数は、説明変数を追加すると必ず上昇する性質を持っている

年収額の重回帰分析

	モデル1		モデル2		モデル3	
	係数	標準誤差	係数	標準誤差	係数	標準誤差
定数	69.377	41.878	113.935	56.033 *	141.477	60.693 *
年齢	11.112	0.961 *	5.354	1.152 *	5.401	1.158 *
労働時間	—	—	1.314	0.722	1.345	0.723
勤続年数	—	—	9.759	1.167 *	9.718	1.169 *
都道府県	—	—	—	—	-1.137	0.879
調査日	—	—	—	—	-0.499	1.126
所要時間	—	—	—	—	0.032	0.116
全平方和	70376201		70376201		70376201	
残差平方和	59188792		53433964		53284581	
回帰平方和	11187410		16942237		17091620	
決定係数	0.159 *		0.241 *		0.243 *	

年収の予測において無意味な3つの説明変数（都道府県・調査日・調査所要時間）を加えても決定係数は上昇してしまう

• 有意水準5%で帰無仮説を棄却できることを示す（定数・回帰係数はt検定、決定係数はF検定）

自由度調整済み決定係数

前ページのような見かけ上の決定係数の上昇を避けるため，説明変数の数を調整した形での決定係数が，モデル（ここでは回帰式）間の比較を行うために用いられる

→ 自由度調整済み決定係数： $Adjusted R^2$ と表記

(coefficient of determination adjusted for the degree of freedom)

$$adjusted R^2 = 1 - \frac{RSS/(N - k - 1)}{TSS/(N - 1)}$$

(N ：データ数， k ：説明変数の数)

ちなみに，前ページの例の $Adjusted R^2$ は，それぞれ0.158, 0.238, 0.236となる．不適切だったモデル2から3の上昇はなくなった．

重回帰分析の結果を読む：係数の検定と信頼区間


結果の真ん中の表に、各係数に関する検定結果である検定統計量とp値（次頁で説明）と、95%信頼区間が示されている

	coef	std err	t	P> t	[0.025	0.975]
Intercept	358.1069	13.117	27.300	0.000	331.091	385.123
農地面積	-0.7711	0.140	-5.514	0.000	-1.059	-0.483
林地面積	0.1720	0.053	3.244	0.003	0.063	0.281
商業地面積	-0.1099	0.048	-2.279	0.031	-0.209	-0.011
密集住宅面積	-0.1941	0.073	-2.675	0.013	-0.344	-0.045

重回帰分析の結果を読む：p値と検定結果

p値とは？：帰無仮説が正しいとした場合、そこで得られる検定統計量よりも極端な統計値が観測される確率のこと．具体的には下図の場所の確率

- 有意水準5%の場合，p値が0.05よりも小さければ，帰無仮説を棄却できる
- 前ページのp値を見ると，すべての係数において，係数の検定を有意水準5%で行うと，すべて棄却できる（回帰係数は0ではなく何らかの意味を持つ）



演習1

次のデータは、ある地域にある 8 つの農産物直売所についての（仮想）データである。売上（千万円/年）を目的変数とし、以下の説明変数を用いて重回帰分析を行う。

- 店舗面積（m²）
- 駐車可能台数（台）
- フリーマーケットの有無（あり=1、なし=0）

(1) 売上に最も影響を与えている要因を比較するために、店舗面積および駐車可能台数を標準化したうえで、重回帰分析を行え。分析にはフリーマーケットの有無も含めてよい。

演習1（続き）

(2) (1) の分析結果をもとにして、売上に最も強い影響を与えていると考えられる説明変数を選べ。

ただし、ここでの「強い影響」は、標準化された回帰係数の大きさに基づいて判断するものとする。

(3) (1) の分析結果において、各説明変数の偏回帰係数に対するt検定の p値を用いて、以下の問いに答えよ。

- 有意水準を 5% に設定すると、3 つすべての説明変数において偏回帰係数は 0 でないと判断される（帰無仮説が棄却される）。
- 一方、有意水準を 1% に設定した場合は、1 つの説明変数のみが有意と判断される。

このとき、有意水準 1% でも有意となる説明変数はどれか。

2. 分散分析と回帰分析

分散分析と回帰分析

これまでの例では、分散分析は、3群以上の平均の差の検定として扱ったが、回帰分析と関連づけることが可能である。は以下のように説明されることがある。

「ある目的変数の散らばり（平方和）を，説明変数により説明された要素と，説明されない要素に分解する分析手法」

- 例えば，施肥量と収量の例の場合，以下のように対応がつく
 - 説明変数：施肥量
 - 目的変数：収量
 - 説明変数により説明された要素：要因による群間変動
 - 説明変数により説明されない要素：群内の誤差変動

回帰分析と分散分析

よって、回帰分析の結果を分散分析によって分析できる

検定統計量は、以下の2つの比である

(説明変数と目的変数を合わせた変数が水準となる．水準数 = 説明変数の数 + 1)

回帰平均平方 = 回帰平方和 / 説明変数の数

$$MS_{REGRESSION} = \frac{ESS}{k}$$

残差平均平方 = 残差平方和 / (データ数 - 説明変数 - 1)

$$MS_{ERROR} = \frac{RSS}{N - k - 1}$$

回帰分析と分散分析

回帰分析の出力には分散分析の結果が含まれている

F-statistic : F値

Prob (F-statistic)」 : F値に対応するp値を表している

OLS Regression Results

```
=====
Dep. Variable:                地価    R-squared:                0.711
Model:                        OLS    Adj. R-squared:           0.664
Method:                      Least Squares    F-statistic:            15.35
Date:                        Tue, 08 Jul 2025    Prob (F-statistic):      1.83e-06
Time:                        02:55:40    Log-Likelihood:         -139.46
No. Observations:            30    AIC:                    288.9
Df Residuals:                25    BIC:                    295.9
Df Model:                    4
Covariance Type:              nonrobust
```

3. 複数の説明変数を持つモデル

教科書添付のノートブックの概要を解説する（教科書 p.451～）

問題の設定

少しわかりやすく言い換えると・・・

あるコンビニチェーンは、2種類のブランドを使って店舗展開していた。

ブランドA：従来型のコンビニ

ブランドB：若者向けの新業態コンビニ（例：ネット連動の強化など）

新業態コンビニが有効かどうかを評価するために、A・Bともに15店舗の売上データを収集した。店舗が立地している地区の人口は異なっているために、そのデータも合わせて収集している。

このデータから、新業態コンビニと、従来型のコンビニでは差があると言えるだろうか？

配慮すべき点

単純に平均をとると・・・（単位は万円？→教科書に明示なし？）

ブランドA：283.707

ブランドB：403.927

おー，新業態いいね → 終了

・・・ではダメ（教科書のモデルlm_dame）

店が立地している人口が多ければ，売上はあがる

→ 人口を配慮した分析が必要

このような，直接の関心はないけれど，何らかの効果を持つような（第3の）変量を
「共変量」と呼ぶ

分析1：人口の影響は共通と仮定

仮定：ブランドAもブランドBも人口の売上への影響は同じ

- 自然な仮定，基本的には売上は人口に比例し，その比例定数は等しい
- 使用するデータは，8-4-1-brand-1.csv

ブランドと人口を説明変数とするモデルを作成する

こちらが，教科書4-4からの分析

→ 結果は，有意な差がない，になる

実はブランドBは人口規模が大きな地域に出店していた（p.457）

分析2：ブランドにより人口からの影響が異なる

仮定：ブランドAとブランドBは，人口の売上への影響が異なる

- 使用するデータは，8-4-2-brand-2.csv
- 例：人口の多い地域は都市部が多く，若年層が多いため，新業態のコンビニの方が売上があがりやすい
 - p.464のグラフはこちらの例に相当
- 例：高齢化が進んでいて，人口の多い地域では，従来型のコンビニの方が売上があがりやすい

交互作用を入れたモデルを作成する

- 交互作用は，ブランドと人口の組からの，売上への影響

→ 結果は，交互作用も有意で，交互作用を入れたモデルが有効

使用する検定について

- 適切な検定結果を出したために，Type I～IIIの検定を使い分けている
- これらは，検定結果を出すための，計算手順などが異なっている
 - 解説例：教科書p.461
- どれを使うかは，教科書を参考にしてほしいが，ケースバイケースの判断になる