

情報数学III

第13回 正規線形モデル：複数の説明変数を持つモデル

鈴木源吾

前回の復習

1. 決定係数
 - 予測の精度と決定係数
2. 分散分析

今回のトピック

1. 重回帰分析

- 重回帰分析とは？
- 重回帰分析の結果を読む
- 自由度調整済み決定係数

2. 分散分析と回帰分析


3. 複数の説明変数を持つモデル

教科書：第8部 第4章

1. 重回帰分析

重回帰分析の必要性

- 第12回に学んだ回帰分析は、1つの目的変数に対して、1つの説明変数を用いて、予測を行おうとした
- しかし、ある事象に影響するような要因は複数もある → 複数の説明変数
- それぞれの説明変数をひとつずつ取り上げ、個別に回帰分析を行うこともできる
- しかし、様々な要因の効果を分析する上では適当ではない



重回帰分析

- そこで，想定される複数の要因を，同時に説明変数とした回帰式を立てて，係数の推定を行う

$$\hat{Y}_i = a + b_1 X_{1i} + b_2 X_{2i} + \cdots + b_k X_{ki}$$

- k個の複数の説明変数それぞれについて，回帰係数が推定されている
→ これらを**偏回帰係数**(partial regression coefficient)と呼ぶ
- このような複数の説明変数の線形結合から目的変数を予測する回帰分析を**重回帰分析**(multiple regression analysis)と呼ぶ
 - 説明変数がひとつの場合の回帰分析を，これと区別して単回帰分析と呼ぶこともある

重回帰分析における係数・定数の決定

- 偏回帰係数・定数の決定は，単回帰分析と同様に**最小二乗法**で行う
 - 残差平方和 $RSS = \sum_i e_i^2$ を最小にする $a, b_1, \dots, b_k$ を求める
- 単回帰では，偏微分=0から**正規方程式**（連立一次方程式）を解いた（第10回）
- 説明変数が複数になると未知数・式が増える → **行列**で書くと見通しがよい
- 以下，行列形式を【発展】として示す（履修済みの線形代数が活きる場面）

【発展】(1) 計画行列とベクトル表現

N 個のデータ・ k 個の説明変数を，行列とベクトルでまとめて書く

$$\underbrace{\begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_N \end{pmatrix}}_{\mathbf{y}} = \underbrace{\begin{pmatrix} 1 & X_{11} & \cdots & X_{k1} \\ 1 & X_{12} & \cdots & X_{k2} \\ \vdots & \vdots & & \vdots \\ 1 & X_{1N} & \cdots & X_{kN} \end{pmatrix}}_{X \text{ (計画行列)}} \underbrace{\begin{pmatrix} a \\ b_1 \\ \vdots \\ b_k \end{pmatrix}}_{\boldsymbol{\beta}} + \underbrace{\begin{pmatrix} e_1 \\ \vdots \\ e_N \end{pmatrix}}_{\mathbf{e}}$$

- これをまとめて $\mathbf{y} = X\boldsymbol{\beta} + \mathbf{e}$ と書ける
- X の1列目は定数項 a のための「1」を並べた列

【発展】（２）正規方程式はなぜこの形になるか

- 第10回の正規方程式は，偏微分を整理すると次を意味していた

$$\frac{\partial S}{\partial a} = 0 \iff \sum_i e_i = 0, \quad \frac{\partial S}{\partial b} = 0 \iff \sum_i e_i X_i = 0$$

- これは「**残差 e が，定数列（全部1）とも説明変数の列 X とも内積0**」ということ
- 重回帰でも同じで，**説明変数ごとに「残差との内積=0」が1本ずつ立つ** → まとめると $X^\top \mathbf{e} = 0$

$$X^\top \mathbf{e} = 0 \xrightarrow{\mathbf{e}=\mathbf{y}-X\boldsymbol{\beta}} X^\top (\mathbf{y} - X\boldsymbol{\beta}) = 0 \implies \boxed{X^\top X \boldsymbol{\beta} = X^\top \mathbf{y}}$$

【発展】（3）正規方程式の解と多重共線性

- 正規方程式を β について解けば，偏回帰係数が一度に求まる

$$X^{\top} X \beta = X^{\top} \mathbf{y} \quad \Longrightarrow \quad \hat{\beta} = (X^{\top} X)^{-1} X^{\top} \mathbf{y}$$

- 第10回の単回帰（説明変数1個）は，この**特殊ケース**

- このとき $X^{\top} X \beta = X^{\top} \mathbf{y}$ は，第10回の正規方程式

$$na + (\sum X_i)b = \sum Y_i, \quad (\sum X_i)a + (\sum X_i^2)b = \sum X_i Y_i \quad \text{と一致する}$$

- $\hat{\beta}$ が一意に求まるには， $X^{\top} X$ が逆行列をもつ（**正則**である）必要がある

- 説明変数どうしが強く相関すると正則に近づけなくなり，係数が不安定に

→ **多重共線性**


- （手計算で逆行列を求める必要はない．計算は statsmodels が行う）

例題1：重回帰分析

- 地価（土地の価格）が周辺環境からどのような影響を受けているのかを調べてみよう
- ノートブックにそのデータが入っている
- 例えば、番号1の地点の地価は、319千円/ m^2 で、その周辺25万 m^2 （500m四方）には、農地が200 m^2 ，林地が400 m^2 ，商業地が16000 m^2 ，密集住宅が7200 m^2 存在していることを示す
- ざっと見た感じでは、ちょっと傾向はわからないが・・・
- ノートブックに計算方法を示す。

重回帰分析の結果を読む：偏回帰係数と定数

- サマリーの真ん中の表の「coef（係数）」の欄に、偏回帰係数と定数の情報がある
- 切片→定数，その他が各説明変数に対する偏回帰係数となる
- 農地面積については，偏回帰係数が-0.771なので，周辺に農地が $100m^2$ 増えると， $1m^2$ あたりの地価が771円下がることを意味する（他の説明変数は一定で）
 - **農地面積が最も目的変数に影響を与える**（回帰係数の絶対値が最大）
- また，林地面積については，地価を上昇させる力があることがわかる

	係数	回帰式
切片	358.107	$Y = 358.107 - 0.771X_1 + 0.172X_2 - 0.110X_3 - 0.194X_4$ 
農地面積	-0.771	
林地面積	0.172	
商業地面積	-0.110	
密集住宅面積	-0.194	

標準偏回帰係数

- 単位が異なる説明変数は、偏回帰係数をそのまま比較できない
 - 例：店舗面積 (m^2) と駐車可能台数 (台) → 「 $1m^2$ あたり」と「1台あたり」の効果は比べられない
- そこで、説明変数を**標準化**（平均0，標準偏差1に変換）してから重回帰分析する
→ 標準化後の係数＝**標準偏回帰係数**（標準化回帰係数）
- 意味：その変数が**1標準偏差**（＝データのばらつき1個分）動いたときの目的変数の変化
→ 単位が消え，絶対値で影響力を比較できる（例は演習1）
- 2値のカテゴリ変数 (0, 1) は標準化しない（「あり／なしの差」として読めなくなる．多値はダミー変数化）
- 目的変数は標準化しなくてもよい（演習1では説明変数のみ標準化）

標準化する？しない？＝何を知らたいかで決める

知りたいこと	使う係数
どの説明変数の影響が強いのか	標準偏回帰係数
実際の単位での効果の解釈・予測	そのままの偏回帰係数

- 実際の単位での解釈の例：「農地が $100m^2$ 増えると地価が771円下がる」（例題1）
- 標準化しても**予測値・決定係数・t値・p値は変わらない**
 - モデルの良し悪しの問題ではなく、**係数の「読み方」を選ぶだけ**
 - どちらかが正解ではない．目的に応じて両方使ってよい

例題1で見比べる：そのまま vs 標準化

	農地面積	林地面積	商業地面積	密集住宅面積
そのまま	−0.771	0.172	−0.110	−0.194
標準化	−30.0	19.7	−13.9	−14.3
p値（どちらも同じ）	0.000	0.003	0.032	0.013

- 影響の強さは係数の**絶対値**で比較する（符号は影響の向き）
 - 最も影響が強いのは農地面積：どちらの係数でも変わらない
- よく見ると，絶対値の2位以下の順位が入れ替わる（林地⇔密集住宅）
 - そのまま＝「同じ量（ $100m^2$ ）動かしたとき」，標準化＝「ばらつき1個分動いたとき」の効き．**別の問い**に答えている
 - 林地はばらつき（標準偏差117 vs 75）が大きく，標準化では上位になる

重回帰分析の結果を読む：決定係数

前回に学んだ決定係数は，サマリーの上の表にある

- 「R-squared」が決定係数である
- 「Adj. R-squared」は自由度調整済み決定係数と呼ばれるもの（次頁説明）

OLS Regression Results

```
=====
Dep. Variable:          地価      R-squared:          0.711
Model:                  OLS      Adj. R-squared:       0.664
Method:                 Least Squares      F-statistic:      15.35
Date:                  Tue, 08 Jul 2025      Prob (F-statistic):  1.83e-06
Time:                  02:55:40      Log-Likelihood:    -139.46
No. Observations:      30      AIC:              288.9
Df Residuals:          25      BIC:              295.9
Df Model:              4
Covariance Type:       nonrobust
```


自由度調整済み決定係数が必要な理由

- 決定係数は，説明変数を追加すると必ず上昇する性質を持っている

年収額の重回帰分析

	モデル 1		モデル 2		モデル 3	
	係数	標準誤差	係数	標準誤差	係数	標準誤差
定数	69.377	41.878	113.935	56.033 *	141.477	60.693 *
年齢	11.112	0.961 *	5.354	1.152 *	5.401	1.158 *
労働時間	—	—	1.314	0.722	1.345	0.723
勤続年数	—	—	9.759	1.167 *	9.718	1.169 *
都道府県	—	—	—	—	-1.137	0.879
調査日	—	—	—	—	-0.499	1.126
所要時間	—	—	—	—	0.032	0.116
全平方和	70376201		70376201		70376201	
残差平方和	59188792		53433964		53284581	
回帰平方和	11187410		16942237		17091620	
決定係数	0.159 *		0.241 *		0.243 *	

年収の予測において無意味な3つの説明変数（都道府県・調査日・調査所要時間）を加えても決定係数は上昇してしまう

• 有意水準 5% で帰無仮説を棄却できることを示す（定数・回帰係数は *t* 検定、決定係数は *F* 検定）

自由度調整済み決定係数

- 見かけ上の上昇を避けるため、説明変数の数 k を考慮した**自由度調整済み決定係数** ($Adjusted R^2$) を、モデル（ここでは回帰式）間の比較に用いる

$$adjusted R^2 = 1 - \frac{RSS/(N - k - 1)}{TSS/(N - 1)}$$

(N : データ数, k : 説明変数の数)

- **なぜ罰則になる？** : k が増えると $N - k - 1$ が小さくなり、 RSS の項が**大きく**なる
→ 追加した変数が RSS を十分減らさない限り、 $Adjusted R^2$ は上がらない
- 前ページの例 : R^2 は $0.159 \rightarrow 0.241 \rightarrow 0.243$ と上がり続けるが、調整済みは $0.158 \rightarrow 0.238 \rightarrow 0.236$ と**モデル3で逆に下がる**（無意味な3変数の罰則）

重回帰分析の結果を読む：係数の検定と信頼区間

結果の真ん中の表に、各係数に関する検定結果である検定統計量とp値と、95%信頼区間が示されている

	coef	std err	t	P> t	[0.025	0.975]
Intercept	358.1069	13.117	27.300	0.000	331.091	385.123
農地面積	-0.7711	0.140	-5.514	0.000	-1.059	-0.483
林地面積	0.1720	0.053	3.244	0.003	0.063	0.281
商業地面積	-0.1099	0.048	-2.279	0.031	-0.209	-0.011
密集住宅面積	-0.1941	0.073	-2.675	0.013	-0.344	-0.045

- p値（ $P>|t|$ ）が0.05より小さければ、帰無仮説「係数=0」を有意水準5%で棄却できる（p値・検定の考え方は第8回）
- この例では、すべての係数で棄却できる（どの回帰係数も0ではなく、何らかの意味を持つ）

演習1

次のデータは、ある地域にある 8 つの農産物直売所についての（仮想）データである。売上（千万円/年）を目的変数とし、以下の説明変数を用いて重回帰分析を行う。

- 店舗面積（ m^2 ）
- 駐車可能台数（台）
- フリーマーケットの有無（あり=1、なし=0）

(1) 売上に最も影響を与えている要因を比較するために、店舗面積および駐車可能台数を標準化したうえで、重回帰分析を行え。分析にはフリーマーケットの有無も含めてよい。

演習1（続き）

(2) (1) の分析結果をもとにして、売上に最も強い影響を与えていると考えられる説明変数を選べ。

ただし、ここでの「強い影響」は、標準化された回帰係数の大きさに基づいて判断するものとする。

(3) (1) の分析結果において、各説明変数の偏回帰係数に対するt検定の p値を用いて、以下の問いに答えよ。

- 有意水準を 5% に設定すると、3 つすべての説明変数において偏回帰係数は 0 でないと判断される（帰無仮説が棄却される）。
- 一方、有意水準を 1% に設定した場合は、1 つの説明変数のみが有意と判断される。

このとき、有意水準 1% でも有意となる説明変数はどれか。

2. 分散分析と回帰分析

分散分析と回帰分析

これまでの例では、分散分析は、3群以上の平均の差の検定として扱ったが、回帰分析と関連づけることが可能であり、以下のように説明されることがある。

「ある目的変数の散らばり（平方和）を，説明変数により説明された要素と，説明されない要素に分解する分析手法」

- 例えば，施肥量と収量の例の場合，以下のように対応がつく
 - 説明変数：施肥量
 - 目的変数：収量
 - 説明変数により説明された要素：要因による群間変動
 - 説明変数により説明されない要素：群内の誤差変動

回帰分析と分散分析

よって、回帰分析の結果を分散分析によって分析できる

検定統計量は、以下の2つの比である

(説明変数と目的変数を合わせた変数が水準となる．水準数 = 説明変数の数 + 1)

回帰平均平方 = 回帰平方和 / 説明変数の数

$$MS_{REGRESSION} = \frac{ESS}{k}$$

残差平均平方 = 残差平方和 / (データ数 - 説明変数 - 1)

$$MS_{ERROR} = \frac{RSS}{N - k - 1}$$

回帰分析と分散分析

回帰分析の出力には分散分析の結果が含まれている

- F-statistic : F値
- Prob (F-statistic) : F値に対応するp値

OLS Regression Results

```
=====
Dep. Variable:          地価      R-squared:          0.711
Model:                OLS      Adj. R-squared:       0.664
Method:             Least Squares      F-statistic:       15.35
Date:                Tue, 08 Jul 2025      Prob (F-statistic): 1.83e-06
Time:                  02:55:40      Log-Likelihood:    -139.46
No. Observations:      30      AIC:              288.9
Df Residuals:          25      BIC:              295.9
Df Model:              4
Covariance Type:      nonrobust
```

3. 複数の説明変数を持つモデル

教科書添付のノートブックの概要を解説する（教科書 p.451～）

問題の設定

少しわかりやすく言い換えると・・・

あるコンビニチェーンは、2種類のブランドを使って店舗展開していた。

ブランドA：従来型のコンビニ

ブランドB：若者向けの新業態コンビニ（例：ネット連動の強化など）

新業態コンビニが有効かどうかを評価するために、A・Bともに15店舗の売上データを収集した。店舗が立地している地区の人口は異なっているために、そのデータも合わせて収集している。

このデータから、新業態コンビニと、従来型のコンビニでは差があると言えるだろうか？

配慮すべき点

単純に売上の平均をとると・・・

ブランドA：283.707

ブランドB：403.927

おー，新業態いいね → 終了

・・・ではダメ（教科書のモデルlm_dame）

店が立地している人口が多ければ，売上はあがる

→ 人口を配慮した分析が必要

このような，直接の関心はないけれど，何らかの効果を持つような（第3の）変量を
「共変量」と呼ぶ

分析1：人口の影響は共通と仮定

仮定：ブランドAもブランドBも人口の売上への影響は同じ

- 自然な仮定，基本的には売上は人口に比例し，その比例定数は等しい
- 使用するデータは，8-4-1-brand-1.csv

ブランドと人口を説明変数とするモデルを作成する

こちらが，教科書4-4からの分析

→ 結果は，有意な差がない，になる

実はブランドBは人口規模が大きな地域に出店していた（p.457）

交互作用とは：効き方そのものが変わる

- 分析1（交互作用なし）：ブランドで**切片**は違うが、人口の効き方（傾き）は共通

$$\text{売上} = a + b_1 \text{ 人口} + b_2 \text{ ブランド}$$


- 交互作用あり：ブランドによって人口の**傾き**まで変わる

$$\text{売上} = a + b_1 \text{ 人口} + b_2 \text{ ブランド} + b_3 (\text{人口} \times \text{ブランド})$$


- ブランドA (=0) の傾きは b_1 ，ブランドB (=1) の傾きは $b_1 + b_3$
- $b_3 \neq 0$ なら傾きが変わる＝**交互作用あり**（2直線が平行でない）
- statsmodels では `売上 ~ 人口 * ブランド`（＝主効果＋交互作用項）と書く

交互作用：平行か，平行でないか

ブランドごとに回帰直線を引いたとき，傾きが揃えば交互作用なし，変われば交互作用あり



人口（交互作用なし：平行）



人口（交互作用あり：傾きが違う）

分析2：ブランドにより人口からの影響が異なる

仮定：ブランドAとブランドBは，人口の売上への影響が異なる

- 使用するデータは，8-4-2-brand-2.csv
- 例：人口の多い地域は都市部で若年層が多い → 新業態（B）の方が売上があがりやすい（p.464のグラフはこの例に相当）
- 例：高齢化が進んだ人口の多い地域 → 従来型（A）の方が売上があがりやすい

交互作用を入れたモデルを作成する

- ブランドによって人口の効き方（傾き）が変わる＝交互作用項 b_3 (人口 × ブランド) を加える

→ 結果は，交互作用も有意で，交互作用を入れたモデルが有効

使用する検定について：Type I～III

分散分析表の作り方（平方和の計算手順）には Type I～III の3種類がある（`anova_lm` の `typ=` で指定）

Type	考え方	特徴
I	式に書いた順に変数を追加して分解	変数を書く 順序で結果が変わる
II	他の説明変数を考慮して各変数を評価	順序によらない．主効果の検定向き
III	交互作用も含めた全ての項を考慮	交互作用のあるモデル で使う

- **基本は Type II**：第12回の分散分析も、今回の分析1も `typ=2`
- **交互作用を入れたら Type III**：分析2は `typ=3`
- Type I は順序で結果が変わるため基本は使わない（解説は教科書 p.461）