

情報数学III

第14回 一般化線形モデル：一般化線形モデルの基本

鈴木源吾

前回の復習

1. 重回帰分析

- 重回帰分析とは？
- 重回帰分析の結果を読む
- 自由度調整済み決定係数

2. 分散分析と回帰分析

3. 複数の説明変数を持つモデル

今回のトピック

1. 回帰分析の適用範囲を広げる
2. 一般化線形モデル
3. ポアソン回帰

教科書：第9部（全体）

1. 回帰分析の適用範囲を広げる

回帰分析の限界

年齢と年収の例を思いだそう。回帰分析を適用することができた。しかし…

- 年収は必ずプラスじゃないといけない
- しかし、直線をずっと左に伸ばすと、マイナスの値になってしまう
- 常にプラスの値をとるようなモデルにすれば、もっと正確に予測できるのでは？

必ず正の値をとるモデルを作るには？

解決策1：関数を利用する

年齢はプラスだから，この場合は問題にはならないが…
(0歳の年収は63.15万円…)

対数関数の利用

正の数が定義域・実数全体が値域 → 対数関数を使えばよい！

必ず正の値をとるモデルを作るには？

解決策2：目的変数は、正の値しかとらない確率分布を使う

回帰分析：目的変数は、正規分布でバラついていた

→ 目的変数が正とわかっているのなら、正の値だけをとる確率分布を使う

ガンマ分布の利用

ガンマ分布の確率密度関数（PDF）は、以下のように表される．

$$f(x; k, \theta) = \frac{1}{\Gamma(k) \theta^k} x^{k-1} e^{-x/\theta}, \quad x > 0$$

- $k > 0$ ：形状パラメータ（shape parameter）
- $\theta > 0$ ：尺度パラメータ（scale parameter）
- $\Gamma(k)$ ：ガンマ関数（階乗の一般化、 $\Gamma(k) = (k - 1)!$ for integer k)

→ 複雑だがポイントは2つだけ，**連続**で，**値域が正の実数**

→ データサイエンスにおける分布の選られ方は，多くが単純

ガンマ分布の（確率密度関数の）グラフ

ガンマ回帰

これらの解決策を活用したモデル作成が、**ガンマ回帰**

- 一般化線形モデル（次節で説明）の一種
- 最尤推定法を用いる
- 解析的に解けないため、数値最適化により解を求める
- 最適化アルゴリズムは、反復重み付き最小二乗法（IRLS）などが用いられる
 - サマリーで, Method: IRLS の表示
- ノートブックに結果を示す

例題をガンマ回帰した結果

- ノートブック参照
- 線形回帰よりも、若干良い結果（p値小さいなど）

2. 一般化線形モデル

一般化線形モデルとは？

一般化線形モデルは、以下の3つを構成要素として持つ

1. 目的変数が従う確率分布
2. 線形予測子
3. リンク関数

1. 目的変数が従う確率分布

- ガンマ回帰では，ガンマ分布が相当する
- 「指数型分布族」と呼ばれるクラスに属していると，モデル推定の計算が容易になる．以下の分布を含む．
 - 正規分布（連続・実数値全体）
 - 二項分布（離散・0か1）
 - ポアソン分布（離散・正の整数）
 - ガンマ分布（連続・正の実数）
- 離散・連続，値域によって，どれを使うかを判断する．

2. 線形予測子

説明変数と係数の線形結合で表される部分である．前の例だと以下となる．

$$\beta_0 + \beta_1 \times \text{年齢}$$

3. リンク関数

目的変数と線形予測子の対応をとるために使う関数．前の例だと以下となる．

$$\log(\text{年収}) = \beta_0 + \beta_1 \times \text{年齢}$$

$\log$ がリンク関数である．

上記を変形すると， $\downarrow$ となるから，年収がマイナスになることはない．

$$\text{年収} = \exp[\beta_0 + \beta_1 \times \text{年齢}]$$

リンク関数と確率分布の対応

目的変数	確率分布 (family)	リンク関数 (link)	モデル名
実数値 (正負あり)	正規分布	恒等関数	線形回帰
0/1 (二値)	二項分布	ロジット関数	ロジスティック回帰
カウントデータ (整数)	ポアソン分布	対数関数	ポアソン回帰
正の連続値	ガンマ分布	対数関数	ガンマ回帰

3. ポアソン回帰

例題：気温とビールの販売個数

例題：気温とビールの販売個数の関係をモデル化したい（教科書の例題）

- ビールの販売個数は、必ずプラスになる

→ リンク関数に対数関数を使う（ガンマ回帰と同じ考え方）

以下のように、リンク関数と線形予測子で表現できる．

$$\log(\text{ビールの販売個数}) = \beta_0 + \beta_1 \times \text{気温}$$

例題：気温とビールの販売個数

- ビールの販売個数は、離散値（10、100など）である

→ 離散の確率分布を使うとよい！

- 離散で、値域がプラスであるような確率分布 → ポアソン分布！
- 第4回で説明済み

ポアソン分布(poisson distribution) (第4回資料)

- 所定時間内にまれに起こる事象が，ある回数（イベント数）発生する確率の分布
 - （1年間に）地震の起こる回数，馬に蹴られて死ぬ兵士数，食中毒の件数
- 母数（パラメータ）が1つ（ λ ）しかないのが特徴
 - 平均も分散も $\lambda \rightarrow$ 平均が大きいとばらつきも大きい

例題の実装

ノートブックで解説

回帰係数の解釈

- 対数関数を介しているなので、最初にやった線形回帰のように、1度あがれば、販売個数が何個増える、とはならない
- 回帰係数のexp（指数関数）をとった値は、1度あがれば、販売個数が何倍になるかを表す
 - 対数では、足し算が掛け算になるから
 - ノートブックに記載

演習

バイクシェアリングの例で，気温とレンタル数の関係をポアソン回帰で調べる