

情報数学III

# 第15回 ロジスティック回帰・ベイズ統計

---

鈴木源吾

注意：ベイズ統計については，参考扱い→最終試験の範囲外

# 前回の復習

---

1. 回帰分析の適用範囲を広げる
2. 一般化線形モデル
3. ポアソン回帰

# 今回のトピック

---

1. ロジスティック回帰
2. 参考：ベイズ統計による線形回帰

教科書：第9部第2章

参考書：

- かくあき「Pythonで動かして学ぶ ベイズ統計の教科書」(翔泳社)
- 久保「データ解析のための統計モデリング入門」(岩波書店)

# 1. ロジスティック回帰

---

# 一般化線形モデルとロジスティック回帰

↓ 前回資料より.

ロジスティック回帰は、二値の目的変数向き（分類）の統計モデル手法

| 目的変数        | 確率分布 (family) | リンク関数 (link) | モデル名      |
|-------------|---------------|--------------|-----------|
| 実数値（正負あり）   | 正規分布          | 恒等関数         | 線形回帰      |
| 0/1（二値）     | 二項分布          | ロジット関数       | ロジスティック回帰 |
| カウントデータ（整数） | ポアソン分布        | 対数関数         | ポアソン回帰    |
| 正の連続値       | ガンマ分布         | 対数関数         | ガンマ回帰     |

# 例：勉強時間と合格率


---

教科書の例題を用いる．ノートブックを参照

- 勉強時間と合否（0・1）の組のデータがある
- 勉強時間→説明変数，合否→目的変数（二値）
- 勉強時間から，合格率を予測したい
- 合格率は，目的変数（合否）の平均である
- 時間毎の合格率を可視化してみる→ノートブック参照



# どんなリンク関数が適している？

- 下の図は、（フライングだが）例のデータから作成された回帰曲線
- 勉強時間と合格率の関係性を表すためには、以下のような特徴を持つ関数が良い
  - 値の範囲が、0から1まで
  - 単調増加．つまり，勉強時間が増えると，合格率があがる



# ロジスティック関数とロジット関数

- ロジスティック関数： $\sigma(x) = \frac{1}{1+e^{-x}}$ 
  - 結果（合格率）はこうなってほしい
- ロジット関数： $\text{logit}(p) = \log\left(\frac{p}{1-p}\right)$ 
  - となると、リンク関数にこれを使えばよい（ロジスティック関数の逆関数）





# ロジスティック回帰を実行してみよう

---

ノートブック参照

- モデルの作成→結果確認
- モデルを使った予測

## 2. 参考：ベイズ統計による線形回帰

---

# ベイズ統計について

---

次に学ぶべき重要なトピックとしてベイズ統計がある．今回は概要と実行例を示す．

- ベイズの定理を利用し，データを元に確率を更新していく
- データをサンプリングする方法と融合している
  - MCMC法（マルコフ連鎖モンテカルロ法）
- すべてのパラメータは，確率変数として扱われる（ベイズ統計の特徴）
  - これまではパラメータは固定した値だった
  - これまでも信頼区間は得られたが，解釈はわかりづらかった
- 事後分布のサンプルが得られ，これまでよりも得られる情報が多い
  - 一点じゃなく分布だから，旧来のパラメータはその平均となる
- 線形モデル・一般化線形モデルについて，対応するベイズ統計版がある

# ベイズの定理とベイズ統計

---

任意の事象  $A \subset \Omega$  に対して、互いに排反な事象の集まり  $B_i (i = 1, \dots, n)$  があって、 $A \subseteq \bigcup_{i=1}^n B_i$  とすると

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(A|B_j)P(B_j)}$$

- 事前確率  $P(B_i)$   $\rightarrow$  事後確率  $P(B_i|A)$
- Aというデータが得られて、確率が更新されたと解釈できる
- ベイズ統計では、事前の確率分布を設定する必要がある

# 参考書と例題について

---

参考書1の線形モデルの例題（車の燃費と重量）をノートブックで紹介する．

- 参考書1：かくあき「Pythonで動かして学ぶ ベイズ統計の教科書」（翔泳社）
  - 教科書と同じシリーズ．Pythonでベイズの教科書は貴重（Rが多い）
  - 説明はあまりわかりやすいとは言えない
  - PyMC3を使用．現在はPyMC v5なので注意（ノートブックは最新）
  - Pythonでベイズ入門だと，PyMCは妥当（実務ではStanがよく使われる）
- 参考書2：久保「データ解析のための統計モデリング入門」（岩波書店）
  - 古くてRだが，わかりやすくて良い本