

情報数学III

第15回 ロジスティック回帰・ベイズ統計

鈴木源吾

注意：ベイズ統計については，参考扱い→最終試験の範囲外

前回の復習

1. 回帰分析の適用範囲を広げる
2. 一般化線形モデル
3. ポアソン回帰

今回のトピック

1. ロジスティック回帰
2. 参考：ベイズ統計による線形回帰
3. まとめ：科目全体の確認と最終試験

教科書：第9部第2～3章

参考書：

- かくあき「Pythonで動かして学ぶ ベイズ統計の教科書」(翔泳社)
- 久保「データ解析のための統計モデリング入門」(岩波書店)

1. ロジスティック回帰

一般化線形モデルとロジスティック回帰

↓ 前回資料より.

ロジスティック回帰は、二値の目的変数向き（分類）の統計モデル手法

目的変数	確率分布 (family)	リンク関数 (link)	モデル名
実数値（正負あり）	正規分布	恒等関数	線形回帰
0/1（二値）	二項分布	ロジット関数	ロジスティック 回帰
カウントデータ（0以上の 整数）	ポアソン分布	対数関数	ポアソン回帰
正の連続値	ガンマ分布	対数関数	ガンマ回帰


例：勉強時間と合格率

教科書の例題を用いる．ノートブックを参照

- 勉強時間と合否（0・1）の組のデータがある
- 勉強時間→説明変数，合否→目的変数（二値）
- 勉強時間から，合格率を予測したい
- 合格率は，目的変数（合否）の平均である
- 時間毎の合格率を可視化してみる→ノートブック参照



どんなリンク関数が適している？

- 下の図は、（フライングだが）例のデータから作成された回帰曲線
- 勉強時間と合格率の関係性を表すためには、以下のような特徴を持つ関数が良い
 - 値の範囲が、0から1まで
 - 単調増加．つまり，勉強時間が増えると，合格率があがる



ロジスティック関数とロジット関数

- ロジスティック関数： $\sigma(x) = \frac{1}{1+e^{-x}}$
 - 結果（合格率）はこうなってほしい
- ロジット関数： $\text{logit}(p) = \log\left(\frac{p}{1-p}\right)$
 - となると、リンク関数にこれを使えばよい（ロジスティック関数の逆関数）



ロジスティック回帰のモデル式

合格率 p と勉強時間の関係は、リンク関数（ロジット関数）で以下のように表される

$$\text{logit}(p) = \beta_0 + \beta_1 \times \text{勉強時間}$$

変形すると（ロジスティック関数はロジット関数の逆関数だから）

$$p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 \times \text{勉強時間})}}$$

- 右辺の $\beta_0 + \beta_1 \times \text{勉強時間}$ は線形予測子（前回資料参照）
- p は「目的変数が1になる確率」。この例では合格率
- この形なら、どんな勉強時間に対しても p は必ず0から1の間に収まる

オッズ：確率のもう1つの表し方

$$\text{オッズ} = \frac{p}{1-p} \quad (\text{起こる確率と起こらない確率の比})$$

- 例：合格率 $p = 0.8$ なら、オッズは $0.8/0.2 = 4$
 - 「合格は不合格より4倍起こりやすい」という意味
- もともとギャンブルで「勝ち目」を表すのに使われてきた
- ロジット関数は、オッズの対数（対数オッズ）である

$$\text{logit}(p) = \log \left(\frac{p}{1-p} \right) = \log(\text{オッズ})$$

ロジスティック回帰を実行してみよう

ノートブック (9-2) 参照

```
mod_glm = smf.glm(formula='result ~ hours', data=test_result,  
                  family=sm.families.Binomial()).fit()
```

- family (確率分布) に二項分布 (Binomial) を指定する
 - リンク関数は、対応するロジット関数が自動で使われる
- summary関数で結果を確認する
 - hoursの係数は0.929, p値は非常に小さい (0.05より遥かに小さい)
 - → 勉強時間は合否に有意に影響している

モデルを使った予測

predict関数で、勉強時間ごとの合格率を予測できる（ノートブック参照）

勉強時間	1時間	5時間	9時間
予測合格率	0.026	0.521	0.978

- 予測値は必ず0から1の間に収まっている
- 推定された係数を使って、ロジスティック関数から手計算もできる

$$p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 \times \text{勉強時間})}}$$

- 回帰曲線の図示もできる（S字カーブ）→ノートブック参照

回帰係数の解釈

- ポアソン回帰（前回）と同様，係数はそのまま「確率が何%増える」とは読めない
- 係数の $\exp$ （指数関数）をとった値は，勉強時間が1時間増えると**オッズが何倍になるか**を表す
 - $\exp(0.929) \approx 2.53 \rightarrow$ 1時間増えるごとに，合格のオッズは約2.5倍
 - この「2つのオッズの比」を**オッズ比**と呼ぶ．ノートブックで一致を確認できる
- 注意：合格率 p そのものが2.5倍になるわけではない

モデル選択：勉強時間を入れるべきか？

- 重回帰（第13回）では，自由度調整済み決定係数でモデルの良し悪しを見た
- 一般化線形モデルでは，**AIC**（赤池情報量規準）がよく使われる
 - モデルの予測の良さを表す指標で，**小さいほど良い**
- 説明変数のないモデル（Nullモデル）とAICを比較する（ノートブック参照）

モデル	AIC
Nullモデル（result ~ 1）	139.99
勉強時間入り（result ~ hours）	72.03

- 勉強時間入りモデルの方がAICが小さい → 勉強時間を入れるべき

参考：一般化線形モデルの評価

線形回帰では、残差（実測値と予測値の差）でモデルを評価できた

→ 一般化線形モデルでは、残差に相当するものに工夫が必要

- ピアソン残差：残差を予測値の標準偏差で割って調整したもの
- deviance残差：当てはまりの悪さ（deviance）に基づく残差
 - devianceは残差平方和の一般化で、小さいほど当てはまりが良い
- 計算例はノートブック（9-3）で紹介

2. 参考：ベイズ統計による線形回帰

ベイズ統計について

次に学ぶべき重要なトピックとしてベイズ統計がある．今回は概要と実行例を示す．

- ベイズの定理を利用し，データを元に確率を更新していく
- データをサンプリングする方法と融合している
 - MCMC法（マルコフ連鎖モンテカルロ法）
- すべてのパラメータは，確率変数として扱われる（ベイズ統計の特徴）
 - これまではパラメータは固定した値だった
 - これまでも信頼区間は得られたが，解釈はわかりづらかった
- 事後分布のサンプルが得られ，これまでよりも得られる情報が多い
 - 一点じゃなく分布だから，旧来のパラメータはその平均となる
- 線形モデル・一般化線形モデルについて，対応するベイズ統計版がある

ベイズの定理とベイズ統計

任意の事象 $A \subset \Omega$ に対して、互いに排反な事象の集まり $B_i (i = 1, \dots, n)$ があって、 $A \subseteq \bigcup_{i=1}^n B_i$ とすると

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(A|B_j)P(B_j)}$$

- 事前確率 $P(B_i)$ $\rightarrow$ 事後確率 $P(B_i|A)$
- Aというデータが得られて、確率が更新されたと解釈できる
- ベイズ統計では、事前の確率分布を設定する必要がある

ベイズ線形回帰の実行例

車の重量と燃費のデータで、最小二乗法とベイズ推定を比較する（ノートブック参照）

- PyMCライブラリを使用．手順は以下の3ステップ
 - i. モデル定義：切片・傾き・誤差のそれぞれに事前分布を設定
 - ii. MCMC法でサンプリングを実行
 - iii. 事後分布を確認（トレースプロット・要約統計量）
- 結果は1本の「確定した直線」ではなく、**不確実性の幅を持った予測**になる
 - 回帰直線の周りに、予測のばらつきの帯を描ける
 - 係数の推定値も点ではなく分布として得られる

参考書と例題について

参考書1の線形モデルの例題（車の燃費と重量）をノートブックで紹介する．

- 参考書1：かくあき「Pythonで動かして学ぶ ベイズ統計の教科書」（翔泳社）
 - 教科書と同じシリーズ．Pythonでベイズの教科書は貴重（Rが多い）
 - 説明はあまりわかりやすいとは言えない
 - PyMC3を使用．現在はPyMC v5なので注意（ノートブックは最新）
 - Pythonでベイズ入門だと，PyMCは妥当（実務ではStanがよく使われる）
- 参考書2：久保「データ解析のための統計モデリング入門」（岩波書店）
 - 古くてRだが，わかりやすくて良い本

3. まとめ：科目全体の確認と最終試験

科目全体の確認：一般化線形モデルのまとめ

モデル	確率分布	リンク関数	用途の例
線形回帰	正規分布	恒等関数	年齢→年収
ポアソン回帰	ポアソン分布	対数関数	気温→販売個数
ガンマ回帰	ガンマ分布	対数関数	正の連続値の予測
ロジスティック回帰	二項分布	ロジット関数	勉強時間→可否

- 使い分けの手順：目的変数の型を見る→確率分布を選ぶ→リンク関数が決まる
 - 連続か離散か，値の範囲（実数全体・正のみ・0/1・0以上の整数）
- 線形回帰も一般化線形モデルの一種（正規分布＋恒等関数）

科目全体のふりかえり

回	テーマ
第1～3回	記述統計：データの分類・統計量・層別分析とグラフ
第4回	確率と確率分布
第5～7回	統計的推定：母集団と標本・点推定・区間推定
第8～9回	統計的仮説検定：平均の検定・差の検定・分割表
第10～13回	統計モデル：回帰分析・分散分析・重回帰
第14～15回	一般化線形モデル：ポアソン回帰・ロジスティック回帰

- 一貫したテーマ：データから何が言えるかを，根拠を持って判断する
- 計算はコンピュータがやってくれる．**結果を読んで判断するのは人間**

最終試験について

- 範囲：第1～15回（ベイズ統計は範囲外）
- ペーパーテストで実施．試験時間は60分
- **ポイント資料（全15回分）は持ち込み可**
 - 15枚すべて揃っているか確認し，整理しておこう
 - MEMO欄の書き込みも持ち込み可．復習しながら書き込むのがおすすめ
- 日程・教室などの詳細はWebClassで連絡する

演習

mtcarsデータセット（車の性能データ）を用いて，変数を選んでロジスティック回帰を実行してみよう

- 例）燃費の高い車はMT（マニュアル車）になりやすいか？
- 変数一覧はノートブックに記載
- 提出方法はこれまでと同じ

授業評価アンケート

これから、情報数学IIIについての授業評価アンケートを行います（約5分）

- キャンパスプランにログイン → 「アンケート」 → 「授業評価アンケート回答」
- 回答前に、Webシラバスで本科目の**学修到達目標**を確認すること
- Q1～Q3は4段階で回答（必須），Q4は自由記述（空欄可）
- 個人情報は一切公表されず，成績評価にも影響しない
 - ただし，自由記述は原文のまま担当教員にフィードバックされる
- 回答が完了した人から退出してよい