

情報数学III

第15回 ロジスティック回帰・ベイズ統計

鈴木源吾

注意：ベイズ統計については，参考扱い→最終試験の範囲外

前回の復習

1. 回帰分析の適用範囲を広げる
2. 一般化線形モデル
3. ポアソン回帰

今回のトピック

1. ロジスティック回帰
2. 参考：ベイズ統計による線形回帰

教科書：第9部第2章

参考書：

- かくあき「Pythonで動かして学ぶ ベイズ統計の教科書」（翔泳社）
- 久保「データ解析のための統計モデリング入門」（岩波書店）

1. ロジスティック回帰

一般化線形モデルとロジスティック回帰

↓ 前回資料より.

ロジスティック回帰は、二値の目的変数向き（分類）の統計モデル手法

目的変数	確率分布 (family)	リンク関数 (link)	モデル名
実数値（正負あり）	正規分布	恒等関数	線形回帰
0/1（二値）	二項分布	ロジット関数	ロジスティック回帰
カウントデータ（整数）	ポアソン分布	対数関数	ポアソン回帰
正の連続値	ガンマ分布	対数関数	ガンマ回帰

例：勉強時間と合格率

教科書の例題を用いる．ノートブックを参照

- 勉強時間と合否（0・1）の組のデータがある
- 勉強時間→説明変数，合否→目的変数（二値）
- 勉強時間から，合格率を予測したい
- 合格率は，目的変数（合否）の平均である
- 時間毎の合格率を可視化してみる→ノートブック参照

どんなリンク関数が適している？

- 下の図は，（フライングだが）例のデータから作成された回帰曲線
- 勉強時間と合格率の関係性を表すためには，以下のような特徴を持つ関数がよい
 - 値の範囲が，0から1まで
 - 単調増加．つまり，勉強時間が増えると，合格率があがる

ロジスティック関数とロジット関数

- ロジスティック関数： $\sigma(x) = \frac{1}{1+e^{-x}}$
 - 結果（合格率）はこうなってほしい
- ロジット関数： $\text{logit}(p) = \log\left(\frac{p}{1-p}\right)$
 - となると，リンク関数にこれを使えばよい（ロジスティック関数の逆関数）

ロジスティック回帰を実行してみよう

ノートブック参照

- モデルの作成→結果確認
- モデルを使った予測

2. 参考：ベイズ統計による線形回帰

ベイズ統計について

次に学ぶべき重要なトピックとしてベイズ統計がある．今回は概要と実行例を示す．

- ベイズの定理を利用し，データを元に確率を更新していく
- データをサンプリングする方法と融合している
 - MCMC法（マルコフ連鎖モンテカルロ法）
- すべてのパラメータは，確率変数として扱われる（ベイズ統計の特徴）
 - これまではパラメータは固定した値だった
 - これまでも信頼区間は得られたが，解釈はわかりづらかった
- 事後分布のサンプルが得られ，これまでよりも得られる情報が多い
 - 一点じゃなく分布だから，旧来のパラメータはその平均となる
- 線形モデル・一般化線形モデルについて，対応するベイズ統計版がある

ベイズの定理とベイズ統計

任意の事象 $A \subset \Omega$ に対して、互いに排反な事象の集まり $B_i (i = 1, \dots, n)$ があって、 $A \subseteq \bigcup_{i=1}^n B_i$ とすると

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(A|B_j)P(B_j)}$$

- 事前確率 $P(B_i)$ $\rightarrow$ 事後確率 $P(B_i|A)$
- Aというデータが得られて、確率が更新されたと解釈できる
- ベイズ統計では、事前の確率分布を設定する必要がある

参考書と例題について

参考書1の線形モデルの例題（車の燃費と重量）をノートブックで紹介する．

- 参考書1：かくあき「Pythonで動かして学ぶ ベイズ統計の教科書」（翔泳社）
 - 教科書と同じシリーズ．Pythonでベイズの教科書は貴重（Rが多い）
 - 説明はあまりわかりやすいとは言えない
 - PyMC3を使用．現在はPyMC v5なので注意（ノートブックは最新）
 - Pythonでベイズ入門だと，PyMCは妥当（実務ではStanがよく使われる）
- 参考書2：久保「データ解析のための統計モデリング入門」（岩波書店）
 - 古くてRだが，わかりやすくて良い本